

Universidad Católica
San Pablo

FACULTAD DE INGENIERÍA Y COMPUTACIÓN
ESCUELA PROFESIONAL DE CIENCIA DE LA COMPUTACIÓN

PLAN DE TESIS · PROYECTO DE FIN DE CARRERA II

Extensión de ST-CC con refinamiento jerárquico por bloques para la detección de patrones espacio-temporales locales

Luis Fabian Diaz Alvizuri
Asesor: Dr. Erick Mauricio Gómez Nieto

Arequipa, octubre de 2026

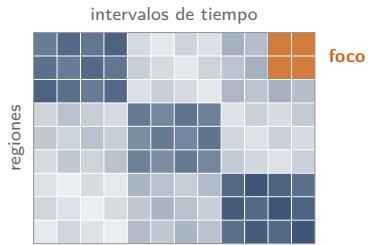
Contexto: ST-CC y el co-agrupamiento en tablero

- Viajes en taxi, sismos y monitoreo ambiental describen dónde y cuándo ocurre un fenómeno, y espacio y tiempo no son independientes [Liu et al., 2021].
- El co-agrupamiento agrupa filas y columnas a la vez. [Liu et al., 2021] proponen ST-CC sobre una matriz de regiones $\times$ intervalos de tiempo, con BBAC$_I$ [Banerjee et al., 2007].
- El resultado es un tablero de $K_R \times K_T$ bloques rectangulares. En Manhattan (noviembre de 2017) usaron unos 10 millones de viajes, 66 regiones y 12 intervalos de 2 horas.
- Es fácil de interpretar, pero la estructura es global.

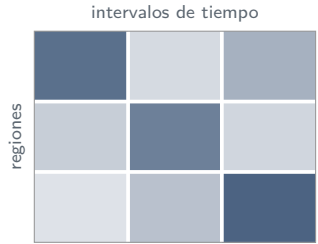


Tablero de ST-CC: cada bloque se resume con un valor

La limitación: un detalle local obliga a refinar todo



(a) Datos: un foco local en un bloque



(b) Tablero de ST-CC: el foco queda promediado

- Cada corte de filas o columnas atraviesa toda la matriz, así que capturar el foco exige aumentar la resolución global y fragmentar zonas sin patrón.
- El paso con K-means de [Liu et al., 2021] reagrupa bloques ya formados, pero no subdivide un bloque por dentro.
- Elegir K_R y K_T con una curva o con Cross-Associations [Chakrabarti et al., 2004] sigue dando una rejilla global.

Planteamiento del problema

Problema

¿Cómo refinar localmente y de forma estadísticamente justificada la partición de ST-CC para detectar patrones espacio-temporales locales, manteniendo la interpretabilidad del resultado?

¿Dónde refinar?

No hay un criterio que diga si un bloque contiene heterogeneidad real que justifique subdividirlo.

¿Cuándo detenerse?

Evaluar muchas divisiones sobre los mismos datos produce refinamientos espurios si no se controla la multiplicidad.

¿Qué es ruido?

La matriz suma varios días con variabilidad mayor que la de Poisson, y con millones de viajes casi todo resulta significativo.

Objetivos

Objetivo general

Proponer y validar una extensión de ST-CC basada en un refinamiento jerárquico por bloques, guiado por pruebas de significancia derivadas de la I-divergencia, que detecte patrones espacio-temporales locales y conserve la interpretabilidad del resultado.

OE1 Formular el refinamiento como un árbol de bloques anidados desde la partición base de BBAC$_I$, con un criterio de heterogeneidad coherente con la función objetivo de ST-CC.

OE2 Diseñar la regla de decisión y de parada: prueba global por bloque, mejor corte, calibración con la variabilidad entre días, control de multiplicidad y umbral de tamaño de efecto.

OE3 Implementar el método y evaluar su calibración y potencia con datos sintéticos y con datos nulos que reproducen la sobredispersión real.

OE4 Aplicarlo a los taxis de Manhattan y compararlo con ST-CC y rejillas globales en error de reconstrucción por parámetro, estabilidad e interpretabilidad.

Estado del arte: tres familias de trabajos desde 2020

Co-agrupamiento y bloques flexibles

Co-clusters coherentes, biclustering con prueba de significancia, modelos de bloques bayesianos y jerárquicos [Wu, 2022, Neves et al., 2022, Yen and Larremore, 2020, Sugahara and Okamoto, 2023, Watanabe and Suzuki, 2021a].

Diferencia. Tableros globales o pruebas como filtro posterior; ninguno decide por bloque cuándo subdividir.

Inferencia selectiva

Pruebas válidas tras agrupar, *count splitting* y *data thinning* [Gao et al., 2024, Chen and Witten, 2023, Watanabe and Suzuki, 2021b, Neufeld et al., 2024b, Neufeld et al., 2024a].

Diferencia. Validan estructuras ya estimadas; ninguno construye un refinamiento jerárquico local.

Hotspots espacio-temporales

Space-time NetScan y detección de focos urbanos en paradas de taxi [Shiode and Shiode, 2022, Chen et al., 2021].

Diferencia. Buscan zonas de alta intensidad en el espacio, no interacciones dentro de bloques de una matriz región $\times$ tiempo.

Puntos de partida. ST-CC [Liu et al., 2021] aporta la partición base. SigTree [Hu et al., 2025] aporta el principio de construir la partición con pruebas de hipótesis y detenerla cuando ninguna división es significativa.

Brecha de investigación

Trabajo	Esp.-temp.	Filas y col.	Estructura local	Criterio estad.	Control de error
ST-CC [Liu et al., 2021]	✓	✓	×	×	×
SigTree [Hu et al., 2025]	×	×	✓	✓	✓
[Wu, 2022]	✓	✓	×	×	×
[Neves et al., 2022]	✓	✓	✓	✓	×
[Watanabe and Suzuki, 2021b]	×	✓	×	✓	✓
[Gao et al., 2024]	×	×	✓	✓	✓
[Shiode and Shiode, 2022]	✓	×	✓	✓	✓
Propuesta (AST-CC)	✓	✓	✓	✓	✓

Brecha

No se encontró un trabajo que refine localmente los bloques de un co-agrupamiento espacio-temporal, decida cada división con una prueba de hipótesis y controle el error a lo largo de la jerarquía.

AST-CC: refinar mientras haya heterogeneidad detectable y relevante



(a) Partición base (ST-CC)



(b) Teselación refinada (AST-CC)

Idea central

Con conteos, la I-divergencia de BBAC_I coincide con la devianza de Poisson. El término que ST-CC no modela es la interacción dentro de cada bloque, medida por G^2_B. Cortar un bloque la reparte exactamente:

$$G^2_B = G^2_{B,s} + \sum_C G^2_C$$

1. Matriz
conteos O y días $X_1, \ldots, X_D$

→

2. Partición base
BBAC_I con K_R, K_T

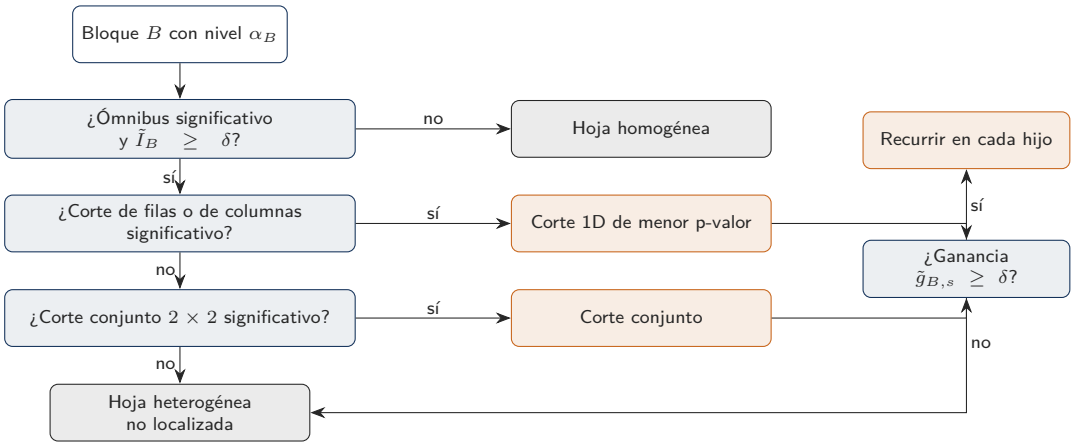
→

3. Refinamiento
pruebas de hipótesis por bloque

→

4. Resumen
hojas, tamaño de efecto y actividad

Regla de decisión para cada bloque

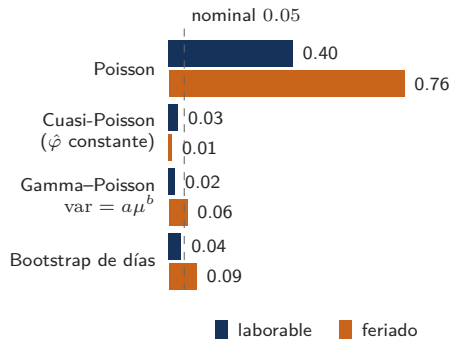


Un corte por nivel; el corte conjunto es el último recurso. Distinguir hojas homogéneas de heterogéneas no localizadas evita presentar como uniforme un bloque que no lo es.

Calibración, multiplicidad y parada

- Bootstrap de días. La varianza entre días es 3 veces la media en días laborables y 17 veces en feriados. Se remuestrean los días, lo que conserva la correlación entre celdas.
- Ajuste min-P [Westfall and Young, 1993]. Se repite la búsqueda del mejor corte en cada réplica nula. Sin ello, el error de tipo I llegó a 0.98.
- Nivel por masa. $\alpha_C = \alpha_B N_C / N_B$ a lo largo del árbol acota el error por familia por α.
- Parada por significancia y tamaño de efecto $\tilde{I}_B \geq \delta$, que no crece con el número de viajes.

Error de tipo I al nivel 0.05 (datos nulos semirreales, media por bloque)



Con pocos días (feriado), el bootstrap es algo liberal en bloques nocturnos. Es una limitación conocida.

Resultados esperados y forma de evaluación

Objetivo	Experimento	Métricas
OE3 Calibración	Datos nulos Poisson y semirreales con la sobredispersión de los días; partición base estimada de los mismos datos	Error de tipo I y FWER al nivel 0.05
OE3 Potencia	Datos sintéticos con patrones locales plantados y distinta intensidad	Tasa de detección, recuperación del patrón (ARI) y falsos positivos
OE4 Datos reales	Taxis de Manhattan (noviembre de 2017, laborable y feriado) frente a ST-CC y rejillas globales con el mismo número de parámetros	Error de reconstrucción por parámetro (BIC), fracción del término (iii) explicada, estabilidad por frecuencia de soporte e interpretabilidad (p. ej. Penn Station)

Resultados esperados

Pruebas calibradas frente a la variabilidad real de los datos; detección de patrones locales que ST-CC y las rejillas más finas no recuperan; menos parámetros para el mismo ajuste; y hojas que se leen directamente como grupos de regiones y de horarios.

Gracias

¿Preguntas?

Referencias I

Banerjee, A., Dhillon, I., Ghosh, J., Merugu, S., and Modha, D. S. (2007).
A generalized maximum entropy approach to Bregman co-clustering and matrix approximation.
Journal of Machine Learning Research, 8:1919–1986.

Chakrabarti, D., Papadimitriou, S., Modha, D. S., and Faloutsos, C. (2004).
Fully automatic cross-associations.
In *Proceedings of the 10th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 79–88.

Chen, X.-J., Wang, Y., Xie, J., Zhu, X., and Shan, J. (2021).
Urban hotspots detection of taxi stops with local maximum density.
Computers, Environment and Urban Systems, 89:101661.

Chen, Y. T. and Witten, D. M. (2023).
Selective inference for k-means clustering.
Journal of Machine Learning Research, 24(152):1–41.

Gao, L. L., Bien, J., and Witten, D. (2024).
Selective inference for hierarchical clustering.
Journal of the American Statistical Association, 119(545):332–342.

Hu, L., Jiang, M., Dong, J., Liu, X., and He, Z. (2025).
Interpretable categorical data clustering via hypothesis testing.
Pattern Recognition, 162:111364.

Referencias II

Liu, Q., Zheng, X., Stanley, H. E., Xiao, F., and Liu, W. (2021).
A spatio-temporal co-clustering framework for discovering mobility patterns: A study of Manhattan taxi data.
IEEE Access, 9:34338–34351.

Neufeld, A., Dharamshi, A., Gao, L. L., and Witten, D. (2024a).
Data thinning for convolution-closed distributions.
Journal of Machine Learning Research, 25(57):1–35.

Neufeld, A., Gao, L. L., Popp, J., Battle, A., and Witten, D. (2024b).
Inference after latent variable estimation for single-cell RNA sequencing data.
Biostatistics, 25(1):270–287.

Neves, F., Finamore, A. C., Madeira, S. C., and Henriques, R. (2022).
Mining actionable patterns of road mobility from heterogeneous traffic data using biclustering.
IEEE Transactions on Intelligent Transportation Systems, 23(7):6430–6445.

Shiode, S. and Shiode, N. (2022).
Network-based space-time scan statistics for detecting micro-scale hotspots.
Sustainability, 14(24):16902.

Sugahara, K. and Okamoto, K. (2023).
Hierarchical co-clustering with augmented matrices from external domains.
Pattern Recognition, 142:109657.

Referencias III

Watanabe, C. and Suzuki, T. (2021a).
Goodness-of-fit test for latent block models.
Computational Statistics & Data Analysis, 154:107090.

Watanabe, C. and Suzuki, T. (2021b).
Selective inference for latent block models.
Electronic Journal of Statistics, 15(1):3137–3183.

Westfall, P. H. and Young, S. S. (1993).
Resampling-Based Multiple Testing: Examples and Methods for p-Value Adjustment.
Wiley, New York.

Wu, X. (2022).
Identification of co-clusters with coherent trends in geo-referenced time series.
ISPRS International Journal of Geo-Information, 11(2):134.

Yen, T.-C. and Larremore, D. B. (2020).
Community detection in bipartite networks with stochastic block models.
Physical Review E, 102(3):032309.