Sección 2.3: Divergencias de Bregman
Notas de estudio

Plan de tesis, Capítulo 2

Índice

I Sección 2.3.1: Definición y propiedades **6**

1. Qué es una divergencia **6**

2. El caso de un solo número **7**
2.1. Qué es ϕ y qué es ϕ' . . . 7
2.2. La fórmula se construye en tres pasos . . . 7
2.3. Ejemplo numérico . . . 7
2.4. Por qué nunca es negativa . . . 8

3. El caso de vectores y matrices **8**
3.1. Una matriz es un vector largo . . . 8
3.2. Qué cambia . . . 8
3.3. Ejemplo numérico con la matriz . . . 8
3.4. Por qué se puede sumar celda por celda . . . 9

4. Propiedades **9**

5. Los tres casos de la tabla y por qué esos ϕ **9**
5.1. Cómo sale la I-divergencia . . . 10
5.2. Por qué la I-divergencia pondera por magnitud . . . 10
5.3. Por qué estos tres en la tesis . . . 10

6. Homogeneidad de la I-divergencia **11**

7. De dónde viene Kullback–Leibler **11**
7.1. Cómo sale de Bregman . . . 11
7.2. Qué mide, con un ejemplo . . . 11
7.3. Por qué no es simétrica . . . 11

8. Cuándo se usa cada divergencia **12**
8.1. I-divergencia: la que se usa con los datos . . . 12
8.2. KL: el puente con la literatura . . . 12
8.3. Euclídea: la referencia . . . 12

II Sección 2.3.2: La media como mejor representante **12**

9. Qué pregunta responde **12**

10. La ecuación, símbolo por símbolo **13**
10.1. El escenario . . . 13
10.2. Cada una de las tres partes . . . 13
10.3. Lo que dice la ecuación . . . 14
10.4. Por qué esto implica que la media es la mejor . . . 14
10.5. Lo sorprendente: vale para cualquier ϕ . . . 14

11. La demostración paso a paso **14**

12. Consecuencia: K-means generalizado **15**

13. Información de Bregman **15**
13.1. Qué es . . . 15
13.2. Con la distancia euclídea es la varianza . . . 15
13.3. Con KL es la información mutua . . . 15
13.4. Por qué importa para la tesis . . . 16

III Sección 2.3.3: Relación con las familias exponenciales **16**

14. Por qué existe esta sección **16**

15. Qué es una familia exponencial **16**

16. El resultado de Banerjee et al. (2005) **17**

17. Verificación para Poisson **17**

18. Por qué minimizar la divergencia equivale a maximizar la verosimilitud **18**

19. Para una matriz completa **18**

IV Sección 2.4: Co-agrupamiento de Bregman **18**

20. Por qué existe esta sección **18**

21. Ejemplo que se usa **19**

22. 2.4.1 Notación **19**
22.1. Las funciones ρ y τ . . . 19
22.2. Los bloques . . . 19
22.3. La lectura probabilística . . . 19

23. 2.4.2 Aproximación y principio de mínima información de Bregman **20**
23.1. La pregunta . . . 20
23.2. Elemento 1: la base $\mathcal{C}$ . . . 20
23.3. Elemento 2: el principio MBI . . . 20
23.4. Cómo se ve en el ejemplo . . . 20
23.5. Propiedades que se mencionan, sin demostrar . . . 21

24. La función objetivo **21**

25.2.4.3 Las seis bases **21**
25.1. Por qué existe esta subsección . . . 21
25.2. Cómo leer la notación . . . 22
25.3. Las seis bases en palabras . . . 22
25.4. La idea de las fórmulas con I-divergencia . . . 22
25.5. Ejemplo: la diferencia entre C2 y C5 . . . 22
25.6. Casos particulares conocidos . . . 23
25.7. La nota sobre C6 . . . 23

26.2.4.4 Algoritmo **23**
26.1. Por qué existe esta subsección . . . 23
26.2. La idea . . . 23
26.3. Los pasos . . . 24
26.4. Ejemplo con la matriz 4×4 . . . 24
26.5. Por qué converge . . . 25
26.6. La limitación: mínimo local . . . 25

V Sección 2.5: La I-divergencia y el modelo de Poisson **25**

27.Por qué existe esta sección **25**

28.2.5.1 Tres bases en notación matricial **26**
28.1. Los totales que se necesitan . . . 26
28.2. Las tres fórmulas . . . 26
28.3. C5 y la información mutua . . . 27
28.4. C6 y la prueba de independencia . . . 27

29.2.5.2 Equivalencia con modelos log-lineales de Poisson **27**
29.1. De dónde viene . . . 27
29.2. Las aproximaciones son los estimadores de máxima verosimilitud . . . 28
29.3. Modelos anidados . . . 28
29.4. Parámetros libres . . . 28

30.2.5.3 Descomposición de la divergencia **28**
30.1. Por qué existe esta subsección . . . 28
30.2. La descomposición . . . 29
30.3. Qué mide cada término . . . 29
30.4. Dos ejemplos que aíslan los términos . . . 29
30.5. Por qué esto justifica G^2 . . . 30
30.6. La advertencia sobre la prueba χ^2 . . . 30

31.2.5.4 Escala de los datos: conteos frente a promedios **30**
31.1. Dos hechos . . . 30
31.2. Por qué importa: promedios diarios . . . 31

VI Sección 2.6: El marco ST-CC **31**

32.Por qué existe en el capítulo 2 **31**

33.Idea general de ST-CC **31**

34.2.6.1 Datos y matriz **31**

35.2.6.2 Primera etapa: co-agrupamiento en tablero **32**

36.2.6.3 Segunda etapa: reagrupar los bloques **32**

37.2.6.4 Lectura de los resultados **32**

38.2.6.5 Limitaciones: las que motivan la tesis **33**

39.2.6.6 Base de co-agrupamiento: ST-CC y esta tesis **33**

VII Sección 2.7: Pruebas de hipótesis para tablas de conteo **33**

40.Por qué existe esta sección **34**

41.2.7.1 Pruebas de independencia **34**
41.1. Los conteos esperados . . . 34
41.2. Dos estadísticos . . . 34
41.3. Por qué la tesis prefiere G^2 . . . 35

42.2.7.2 Pruebas condicionales y p-valores por simulación **35**
42.1. El problema de la χ^2 . . . 35
42.2. La idea: condicionar sobre los totales . . . 35
42.3. Simulación (Patefield) . . . 35
42.4. Simulación secuencial (Besag y Clifford) . . . 36
42.5. El estadístico puede ser cualquiera . . . 36

43.2.7.3 Remuestreo de réplicas independientes **36**
43.1. Por qué hace falta otro método . . . 36
43.2. El bootstrap . . . 36
43.3. Tres detalles . . . 36

44.2.7.4 Comparaciones múltiples **37**
44.1. El problema . . . 37
44.2. Dos formas de medir el error . . . 37
44.3. Las correcciones . . . 37
44.4. Pruebas jerárquicas . . . 37
44.5. La estructura que usa este problema . . . 38

45.2.7.5 Inferencia después de la selección **38**
45.1. El problema del doble uso de los datos . . . 38
45.2. Tres remedios . . . 38
45.3. Count splitting (Neufeld et al., 2024) . . . 38

46.2.7.6 Tamaño de efecto y sobredispersión **39**
46.1. Tamaño de efecto: el problema de los millones de viajes . . . 39
46.2. El sesgo de la información mutua empírica . . . 39
46.3. Sobredispersión . . . 39
46.4. Funciones de varianza . . . 40
46.5. El límite de todos estos modelos . . . 40

VIII Sección 2.8: SigTree **40**

47.Por qué existe esta sección **40**
47.1. Antecedente: CHAID 40

48.2.8.1 Divisiones candidatas y pseudo-clases **41**

49.2.8.2 Estadístico y criterio de división **41**
49.1. Ejemplo numérico 41

50.2.8.3 Criterios de parada **42**

51.2.8.4 Limitaciones **42**

52.2.8.5 Relación con la propuesta **42**

IX Capítulo 3, bloque 1: visión general y formulación **43**

53.Por qué existe el capítulo **43**

54.3.1 Visión general **43**

55.3.2 Formulación **44**
55.1. Notación y la cantidad central 44
55.2. Corte, árbol y modelo local 44
55.3. La proposición clave 44
55.4. Relación con ST-CC (el corolario) 45
55.5. Planteamiento del problema 45

X Capítulo 3, bloque 2: estadísticos y regla de decisión **45**

56.Por qué existen estas secciones **46**

57.3.3 Estadísticos de heterogeneidad **46**
57.1. 3.3.1 Elección del modelo nulo 46
57.2. 3.3.2 Prueba ómnibus 46
57.3. 3.3.3 Pruebas dirigidas 46
57.4. 3.3.4 Generación de cortes candidatos 47

58.Por qué el límite es 14 filas **47**

59.3.4 Regla de decisión **48**

XI Capítulo 3, bloque 3: calibración de las pruebas **49**

60.Por qué existe esta sección **49**

61.3.5.1 Variabilidad entre días **49**

62.3.5.2 *Bootstrap* de días **50**

63.3.5.3 Corrección por la búsqueda del mejor corte **51**

64.3.5.4 Alcance de la corrección **51**

XII Capítulo 3, bloque 4: comparaciones múltiples y criterios de parada 52

65.Por qué existen estas secciones 52

66.3.6 Control de comparaciones múltiples 52

67.3.7 Criterios de parada 53

XIII Capítulo 3, bloque 5: el algoritmo 54

68.Por qué existe esta sección 54

69.3.8 Algoritmo 54

69.1. Algoritmo 1: Refinar . . . 54
69.2. Algoritmo 2: MejorCorte con *min-P* . . . 55
69.3. La tabla de parámetros . . . 55
69.4. Costo computacional . . . 55

XIV Capítulo 3, bloque 6: representación de los resultados 56

70.Por qué existe esta sección 56

71.3.9 Los cinco productos 56

71.1. 1. Descriptores de hoja . . . 56
71.2. 2. Árbol anotado . . . 57
71.3. 3. Matriz teselada . . . 57
71.4. 4. Mapas de profundidad . . . 57
71.5. 5. Frecuencia de soporte . . . 57

XV Capítulo 3, bloque 7: limitaciones y cierre 58

72.Por qué existe esta sección 58

73.3.10 Las ocho limitaciones 58

74.Extensiones que quedan como trabajo futuro 59

75.Consideraciones finales del capítulo 60

Parte I

Sección 2.3.1: Definición y propiedades

1. Qué es una divergencia

Al agrupar datos, cada grupo se resume con un *representante*, y hace falta medir cuánto se pierde al reemplazar cada dato x por su representante y. Esa medida de pérdida es una divergencia.

Se parece a una distancia, pero no lo es: en general no es simétrica y no cumple la desigualdad triangular. Por eso se la llama divergencia.

La distancia euclídea al cuadrado, $(x-y)^2$, trata igual un error de 10 viajes en una celda de 100 y en una de 10 000. Las divergencias de Bregman permiten construir medidas que sí distinguen esos casos: se elige una función ϕ según el tipo de dato y de ella sale la medida.

2. El caso de un solo número

2.1. Qué es ϕ y qué es ϕ'

ϕ es una función *estrictamente convexa*: una curva en forma de U, sin tramos rectos. ϕ' es su *derivada*: para cada punto y dice qué tan inclinada está la curva en ese punto, es decir, su *pendiente*.

Ejemplo con $\phi(x) = x^2$, cuya derivada es $\phi'(x) = 2x$:

Punto y	$\phi(y)$ (altura de la curva)	$\phi'(y)$ (pendiente)	Lectura
0	0	0	la curva está plana
1	1	2	sube 2 por cada unidad
3	9	6	más empinada

2.2. La fórmula se construye en tres pasos

1. **La tangente en y.** Es la recta que toca la curva solo en y y tiene su misma inclinación. Parte de la altura $\phi(y)$ y sube $\phi'(y)$ por cada unidad que avanzas. Al moverte de y a x (distancia $x-y$), su altura en x es

$$\text{tangente}(x) = \phi(y) + \phi'(y)\,(x-y).$$

2. **La curva en** x tiene altura $\phi(x)$.

3. **La divergencia** es cuánto queda la curva por encima de la tangente en x:

$$d_\phi(x,y) = \phi(x) - \big[\phi(y) + \phi'(y)(x-y)\big].$$

Quitando el corchete se obtiene la fórmula de la tesis:

$$d_\phi(x,y) = \phi(x) - \phi(y) - \phi'(y)\,(x-y). \tag{1}$$

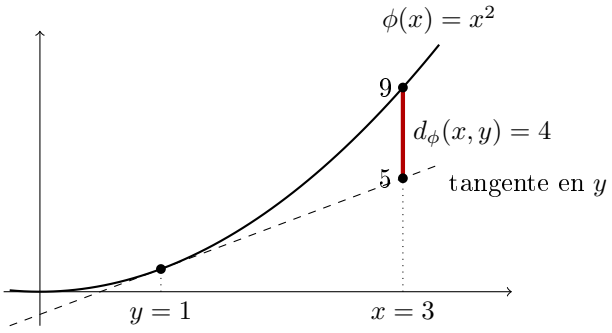
No hay nada más detrás de la fórmula: es una resta entre la curva y la tangente.

2.3. Ejemplo numérico

Con $\phi(x) = x^2$, representante $y = 1$ y dato $x = 3$:

- Curva en x: $\phi(3) = 9$.
- Tangente en x: $\phi(1) + \phi'(1)(3-1) = 1 + 2\cdot 2 = 5$.
- Divergencia: $9 - 5 = \mathbf{4}$, que es $(3-1)^2$. Es la línea gruesa vertical de la figura de la tesis.

En general, con $\phi(x) = x^2$: $x^2 - y^2 - 2y(x-y) = x^2 - 2xy + y^2 = (x-y)^2$.



2.4. Por qué nunca es negativa

Porque ϕ es una U: siempre queda *por encima* de cualquiera de sus tangentes. Por eso curva − tangente ≥ 0, y vale 0 solo cuando $x = y$ (ahí curva y tangente se tocan). Convexidad implica divergencia no negativa.

3. El caso de vectores y matrices

3.1. Una matriz es un vector largo

Una matriz de conteos 2×2 (origen $\times$ hora), por ejemplo $\begin{pmatrix} 100 & 20 \\ 30 & 50 \end{pmatrix}$, se aplana en un vector con 4 componentes: $x = (100, 20, 30, 50)$. Lo mismo se hace con el representante y (la aproximación por bloques). Cada celda es una componente.

3.2. Qué cambia

- ϕ **recibe un vector** y devuelve un número. Ya no es una curva sino una superficie (un «cuenco» en más dimensiones).
- **Hay una pendiente por componente.** En una superficie puedes moverte en cada dirección y la inclinación es distinta en cada una. El vector de pendientes es el *gradiente*

$$\nabla\phi(y) = \left(\frac{\partial\phi}{\partial y_1}, \ldots, \frac{\partial\phi}{\partial y_p}\right),$$

  donde cada entrada es la derivada de ϕ respecto a esa componente dejando las demás fijas. Es la generalización de ϕ'.
- **La tangente es un plano** (hiperplano). Su altura en x es $\phi(y) + \sum_k (x_k - y_k)\, \partial\phi/\partial y_k$.
- La suma $\sum_k a_k b_k$ se escribe $\langle a, b\rangle$ y se llama producto interno: multiplica componente a componente y suma.

La idea es la misma, curva − plano tangente:

$$d_\phi(x, y) = \phi(x) - \phi(y) - \langle x - y, \nabla\phi(y)\rangle. \tag{2}$$

Con una sola componente, (2) coincide con (1).

3.3. Ejemplo numérico con la matriz

Sea $\phi(x) = \sum_k x_k^2$, de modo que $\partial\phi/\partial y_k = 2y_k$. Con $y = (60, 60, 60, 60)$ y $x = (100, 20, 30, 50)$:

- $\phi(x) = 10\,000 + 400 + 900 + 2\,500 = 13\,800$.

- $\phi(y) = 4 \cdot 3\,600 = 14\,400$.
- $\nabla\phi(y) = (120, 120, 120, 120)$.
- $x - y = (40, -40, -30, -10)$, cuya suma es -40.
- $\langle x - y, \nabla\phi(y)\rangle = 120 \cdot (-40) = -4\,800$.
- $d = 13\,800 - 14\,400 - (-4\,800) = \mathbf{4\,200}$.

Comprobación: $\sum_k (x_k - y_k)^2 = 1\,600 + 1\,600 + 900 + 100 = 4\,200$. Coincide con la distancia euclídea al cuadrado.

3.4. Por qué se puede sumar celda por celda

Si ϕ es una suma de una misma función ψ aplicada a cada celda, $\phi(x) = \sum_k \psi(x_k)$, entonces $\partial\phi/\partial y_k = \psi'(y_k)$ solo depende de la celda k. Al sustituir, todo se separa:

$$d_\phi(x, y) = \sum_k \Big[\psi(x_k) - \psi(y_k) - \psi'(y_k)(x_k - y_k)\Big] = \sum_k d_\psi(x_k, y_k).$$

Por eso la discrepancia entre dos matrices se calcula como la suma de la divergencia escalar de cada celda.

4. Propiedades

Propiedad	**Por qué**
$d \geq 0$, y $d = 0$ solo si $x = y$	La tangente está bajo la curva y ϕ es estrictamente convexa.
Convexa en el primer argumento x	$\phi(x)$ es convexa y el resto es lineal en x. En el segundo argumento no lo es en general.
No simétrica: $d(x, y) \neq d(y, x)$	La tangente se traza en y (el representante), no en x (el dato).
No cumple la desigualdad triangular	Por eso no es una métrica y se llama divergencia.
Aditiva por componentes	Si $\phi(x) = \sum \psi(x_k)$, entonces $d(x, y) = \sum d(x_k, y_k)$. Permite sumar celda por celda.

5. Los tres casos de la tabla y por qué esos ϕ

No hay nada mágico en esos tres: ϕ **es una elección de modelado**. Se elige la curva según cómo se comporta el error en los datos. Cada ϕ corresponde a un supuesto distinto sobre cómo varía el error con la magnitud del dato.

$\phi(x)$	$d_\phi(x, y)$	Qué supone sobre el error	Tipo de dato
x^2	$(x-y)^2$	Constante en todas partes (varianza constante, como una gaussiana)	Medidas continuas
$x \log x - x$	$x \log \frac{x}{y} - (x-y)$	Crece con el tamaño de la celda (varianza proporcional a la media, como Poisson)	Conteos
$\sum_k x_k \log x_k$	$\sum_k x_k \log \frac{x_k}{y_k}$	Igual que el anterior, pero con datos que suman 1	Distribuciones de probabilidad

5.1. Cómo sale la I-divergencia

Con $\phi(x) = x \log x - x$, la derivada es $\phi'(x) = \log x$ (la derivada de $x \log x$ es $\log x + 1$ y la de $-x$ es -1, que se cancelan). Sustituyendo en (1):

$$\begin{aligned} d(x, y) &= x \log x - x - (y \log y - y) - \log y \, (x - y) \\ &= x \log x - x - y \log y + y - x \log y + y \log y \\ &= x \log \frac{x}{y} - (x - y). \end{aligned}$$

El caso de Kullback–Leibler es el mismo cálculo sobre el símplex: como $\sum_k x_k = \sum_k y_k = 1$, el término $-(x-y)$ se anula al sumar.

5.2. Por qué la I-divergencia pondera por magnitud

Una diferencia de 10 viajes (dato 110, representante 100):

$$d = 110 \ln 1.1 - 10 = 10.484 - 10 \approx \mathbf{0.48}.$$

La misma diferencia en una celda grande (dato 10 010, representante 10 000):

$$d = 10\,010 \ln 1.001 - 10 \approx \mathbf{0.005}.$$

La distancia euclídea da 100 en ambos casos. Atención: la divergencia no es simétrica; con dato 90 y representante 100 el primer valor sería 0.52, por eso conviene decir siempre cuál es el dato y cuál el representante.

La razón de fondo es que, cerca de y, la divergencia se comporta como

$$d_\phi(x, y) \approx \tfrac{1}{2} \, \phi''(y) \, (x - y)^2.$$

La segunda derivada de ϕ es el «peso» que se da al error en cada punto: para x^2 es constante ($\phi'' = 2$); para $x \log x - x$ es $\phi'' = 1/x$, que disminuye cuando x crece. Ese es el comportamiento de un modelo de Poisson, donde la varianza crece con la media.

5.3. Por qué estos tres en la tesis

- **Euclídea:** referencia clásica (k-means), sirve para comparar.
- **I-divergencia:** la que se usa de verdad, porque los datos son conteos de viajes; corresponde exactamente al modelo de Poisson (Sección 2.3.3).
- **Kullback–Leibler:** caso particular de la I-divergencia con datos que suman 1; es la que aparece en la literatura de co-agrupamiento.

Existen más divergencias de Bregman (Itakura–Saito, Mahalanobis, ...), pero la tesis se queda con las tres que necesita.

6. Homogeneidad de la I-divergencia

Si dato y representante se multiplican por una misma constante $c > 0$, la divergencia queda multiplicada por c:

$$d_I(cx, cy) = cx \log \frac{x}{y} - c(x - y) = c\, d_I(x, y).$$

Esto se usa más adelante para comparar conteos y promedios (sección «Escala de los datos»).

7. De dónde viene Kullback–Leibler

KL (Kullback–Leibler) es una divergencia pensada para **comparar dos distribuciones de probabilidad**, es decir, dos listas de números que suman 1. Responde a esta pregunta: si la realidad es x y se la describe con el modelo y, ¿cuánto se pierde?

$$KL(x \,\|\, y) = \sum_k x_k \log \frac{x_k}{y_k}.$$

7.1. Cómo sale de Bregman

Se elige $\phi(x) = \sum_k x_k \log x_k$. Su derivada respecto a cada componente es $\log x_k + 1$. Sustituyendo en la definición:

$$d(x, y) = \sum_k x_k \log x_k - \sum_k y_k \log y_k - \sum_k (x_k - y_k)(\log y_k + 1).$$

Se desarrolla el último término, $\sum_k (x_k - y_k) \log y_k + \sum_k (x_k - y_k)$. Al restarlo, los términos con $y \log y$ se cancelan y queda

$$d(x, y) = \sum_k x_k \log \frac{x_k}{y_k} - \sum_k (x_k - y_k).$$

Si x e y son distribuciones, ambas suman 1, así que $\sum_k (x_k - y_k) = 1 - 1 = 0$ y el último término desaparece. Queda exactamente KL. Por eso KL es la I-divergencia cuando los datos suman 1: es el mismo cálculo, solo que aquí el término $-(x - y)$ se anula.

7.2. Qué mide, con un ejemplo

La realidad x es un dado cargado y el modelo y es un dado justo:

Cara	1	2	3 y 4
Real x	0.5	0.5	0
Modelo y	0.25	0.25	0.25

$$KL(x\|y) = 0.5 \ln \frac{0.5}{0.25} + 0.5 \ln \frac{0.5}{0.25} = \ln 2 \approx 0.693.$$

Las caras 3 y 4 no aportan porque $x = 0$ ahí y se usa la convención $0 \log 0 = 0$. Si $y = x$, todos los $\log(x/y)$ valen 0 y KL $= 0$; cuanto más se parece el modelo a la realidad, menor es KL. Otra lectura equivalente: KL es el número extra de bits que se gastan al codificar los datos con el código del modelo y en lugar del código óptimo para x.

7.3. Por qué no es simétrica

Con los mismos números, $KL(y\|x)$ falla porque x vale 0 donde y no: aparece $\log(0.25/0)$, que es infinito. Entonces $KL(x\|y) \neq KL(y\|x)$, igual que ocurre con las divergencias de Bregman en general.

KL compara dos distribuciones. Sale de Bregman con $\phi = \sum x \log x$. Vale 0 si son iguales y crece cuanto más se alejan.

8. Cuándo se usa cada divergencia

Cada una cumple un papel distinto en la tesis. Solo una es la que se aplica a los datos; las otras dos están por referencia y por teoría.

Divergencia	Papel en la tesis	Dónde aparece
I-divergencia	Es la que se aplica a los datos reales.	Base de co-agrupamiento (C5 adoptada, C2 como variante) y vínculo con Poisson
Kullback–Leibler	Conecta con la literatura del co-agrupamiento por información mutua.	Función objetivo declarada por Liu et al. (2021), la pérdida de información mutua
Euclídea	Es el caso clásico y la referencia para comparar.	K-means, varianza, bloques constantes (Cho et al., 2004)

8.1. I-divergencia: la que se usa con los datos

La matriz de co-ocurrencia son **conteos de viajes**, no medidas continuas. Para conteos, la I-divergencia es la apropiada por dos razones: pondera el error según el tamaño de la celda (una diferencia de 10 viajes pesa mucho en una celda de 100 y casi nada en una de 10 000) y es exactamente la divergencia del modelo de Poisson, de modo que minimizarla equivale a maximizar la verosimilitud de Poisson (Parte III).

8.2. KL: el puente con la literatura

KL es la I-divergencia cuando los datos suman 1. Se necesita porque la función objetivo que declaran Liu et al. es la pérdida de información mutua $I(R;T) - I(\hat{R};\hat{T})$, y la información mutua se define con KL. Sin KL no se podría explicar la diferencia entre lo que declara ese trabajo (base C5) y lo que parece implementar su código (base C2).

8.3. Euclídea: la referencia

No es la apropiada para conteos, pero cumple tres papeles: es el punto de partida didáctico (la que todo el mundo conoce), es la divergencia con la que se explican primero K-means, la media como mejor representante y la varianza, y es la que usa el co-agrupamiento clásico de bloques constantes.

> I-divergencia: los datos. KL: la literatura de información mutua. Euclídea: la intuición y la comparación.

Parte II
Sección 2.3.2: La media como mejor representante

9. Qué pregunta responde

Cada grupo de datos se resume con **un solo número**, el representante. La pregunta es: ¿qué número elegir para que, en promedio, el error al reemplazar cada dato por él sea el menor

posible? La respuesta de esta sección es que, para *cualquier* divergencia de Bregman, el mejor representante es la media del grupo.

Esto importa porque hace posible un algoritmo tipo K-means: se asigna cada dato al representante más cercano y luego se recalcula cada representante como la media de su grupo. Sin esta propiedad no habría una forma simple de recalcular los centroides.

10. La ecuación, símbolo por símbolo

$$\mathrm{E}[d_\phi(X, s)] = \mathrm{E}[d_\phi(X, \mu)] + d_\phi(\mu, s).$$

10.1. El escenario

Un grupo de datos: las celdas 1, 2 y 6 de un bloque. Se quiere resumirlo con un solo número.

Símbolo	Qué significa	En el ejemplo
X	Un dato del grupo, tomado al azar	Puede ser 1, 2 o 6, cada uno con probabilidad 1/3
μ	La media del grupo, $\mu = \mathrm{E}[X]$	$(1 + 2 + 6)/3 = 3$
s	Cualquier candidato a representante	2, 3, 4, 10… lo que se quiera probar
$d_\phi(a, b)$	El error de reemplazar a por b (Sección 2.3.1)	Con $\phi = x^2$ es $(a - b)^2$
$\mathrm{E}[\cdots]$	El promedio sobre todos los datos del grupo	Se suma el error de cada dato y se divide entre 3

$\mathrm{E}[X]$ es el promedio de los datos y $\mathrm{E}[d(X, s)]$ es el promedio de los errores: primero se calcula el error de cada dato y luego se promedian.

10.2. Cada una de las tres partes

Lado izquierdo, $\mathrm{E}[d_\phi(X, s)]$: el error promedio si se elige s. Con $\phi = x^2$ y $s = 2$:

- dato 1: $(1 - 2)^2 = 1$; dato 2: $(2 - 2)^2 = 0$; dato 6: $(6 - 2)^2 = 16$;
- promedio: $(1 + 0 + 16)/3 = \mathbf{17/3 \approx 5.67}$.

Primer término de la derecha, $\mathrm{E}[d_\phi(X, \mu)]$: el error promedio si se elige la media. Con $\mu = 3$:

- $(1 - 3)^2 = 4$; $(2 - 3)^2 = 1$; $(6 - 3)^2 = 9$;
- promedio: $(4 + 1 + 9)/3 = \mathbf{14/3 \approx 4.67}$, menor que 5.67.

Segundo término de la derecha, $d_\phi(\mu, s)$: el error de reemplazar la media por el candidato. Aquí ya no hay promedio ni datos individuales: es un solo número, qué tan lejos está el candidato de la media. $(\mu - s)^2 = (3 - 2)^2 = \mathbf{1}$.

10.3. Lo que dice la ecuación

$$\underbrace{\tfrac{17}{3}}_{\text{error con } s=2} = \underbrace{\tfrac{14}{3}}_{\text{error con la media}} + \underbrace{1}_{\text{lejanía de } s \text{ a la media}}.$$

El error de usar cualquier representante s es el error de usar la media más un castigo por haberse alejado de ella.

10.4. Por qué esto implica que la media es la mejor

El castigo $d_\phi(\mu, s)$ es una divergencia: nunca es negativa y vale 0 solo cuando sus dos argumentos son iguales. Si $s = \mu$, el castigo es 0 y el error es el mínimo posible. Si $s \neq \mu$, el castigo es positivo y el error es mayor.

Candidato s	Error promedio	Castigo $(\mu - s)^2$
1	$(0 + 1 + 25)/3 = 8.67$	4
2	$(1 + 0 + 16)/3 = 5.67$	1
3 (la media)	$\mathbf{(4 + 1 + 9)/3 = 4.67}$	**0**
4	$(9 + 4 + 4)/3 = 5.67$	1
5	$(16 + 9 + 1)/3 = 8.67$	4

En cada fila, error = 4.67+ castigo. La media es la única que no paga castigo.

10.5. Lo sorprendente: vale para cualquier ϕ

Con la I-divergencia los números cambian: el error con la media es 0.750 y con $s = 2$ es 0.966. La diferencia es 0.216, que es $d_I(3, 2) = 3 \ln 1.5 - 1 = 0.216$. La forma es idéntica: error con s = error con la media + castigo.

11. La demostración paso a paso

(Esta parte es para entender por qué se cumple; no va en la tesis.) Se abre cada divergencia con la definición $d_\phi(a, b) = \phi(a) - \phi(b) - \langle a - b, \nabla\phi(b)\rangle$. Solo hace falta que el promedio es lineal y que las constantes salen del promedio.

Paso 1, lado izquierdo. $\mathrm{E}[d_\phi(X, s)] = \mathrm{E}\big[\phi(X) - \phi(s) - \langle X - s, \nabla\phi(s)\rangle\big]$. Se promedia cada pedazo: $\mathrm{E}[\phi(X)]$ queda igual; $\phi(s)$ es fijo; y $\mathrm{E}[\langle X - s, \nabla\phi(s)\rangle] = \langle \mu - s, \nabla\phi(s)\rangle$.

$$\textbf{(A)} \quad \mathrm{E}[d_\phi(X, s)] = \mathrm{E}[\phi(X)] - \phi(s) - \langle \mu - s, \nabla\phi(s)\rangle.$$

Paso 2, primer término de la derecha. $\mathrm{E}[d_\phi(X, \mu)] = \mathrm{E}\big[\phi(X) - \phi(\mu) - \langle X - \mu, \nabla\phi(\mu)\rangle\big]$. El último pedazo es $\langle \mathrm{E}[X] - \mu, \nabla\phi(\mu)\rangle = \langle 0, \nabla\phi(\mu)\rangle = 0$. Este es el momento clave: desaparece porque el promedio de X es justamente μ, así que $\mathrm{E}[X - \mu] = 0$. Es la única vez que se usa que μ es la media.

$$\textbf{(B)} \quad \mathrm{E}[d_\phi(X, \mu)] = \mathrm{E}[\phi(X)] - \phi(\mu).$$

Paso 3, segundo término de la derecha. Sin promedio, solo la definición:

$$\textbf{(C)} \quad d_\phi(\mu, s) = \phi(\mu) - \phi(s) - \langle \mu - s, \nabla\phi(s)\rangle.$$

Paso 4. Al sumar (B) y (C), los términos $-\phi(\mu)$ y $+\phi(\mu)$ se cancelan y queda $\mathrm{E}[\phi(X)] - \phi(s) - \langle \mu - s, \nabla\phi(s)\rangle$, que es exactamente (A).

Comprobación numérica ($\phi = x^2$, datos 1, 2, 6, $\mu = 3$, $s = 2$): $\mathrm{E}[\phi(X)] = 41/3 \approx 13.67$, $\phi(s) = 4$ y $\langle \mu - s, \nabla\phi(s)\rangle = 1 \cdot 4 = 4$. Entonces (A) $= 13.67 - 4 - 4 = 5.67$, (B) $= 13.67 - 9 = 4.67$, (C) $= 9 - 4 - 4 = 1$, y (B)+(C) $= 5.67 =$ (A).

El truco es que en (B) el término lineal se hace cero, y eso solo ocurre cuando el centro del promedio es la media: es el único punto alrededor del cual los desvíos $X - \mu$ se compensan.

12. Consecuencia: K-means generalizado

El algoritmo alterna dos pasos: **asignar** cada dato al representante con menor $d_\phi(x, \text{representante})$ y **actualizar** cada representante como la media de su grupo. El segundo paso baja el error (la media es el mejor representante) y el primero también, por lo que el algoritmo converge para cualquier divergencia de Bregman. El recíproco (Banerjee et al.) dice que esto solo ocurre con las divergencias de Bregman: bajo condiciones suaves, ninguna otra pérdida tiene a la media como predictor óptimo.

13. Información de Bregman

$$I_\phi(X) = \mathrm{E}\big[d_\phi(X, \mathrm{E}[X])\big].$$

13.1. Qué es

Es el error que queda **incluso usando el mejor representante**, la media. Es el término "error promedio con la media" de la ecuación anterior, al que solo se le da nombre. Mide cuánta variabilidad tiene el grupo. Si todos los datos son iguales, la media los representa sin error y $I = 0$; si están muy dispersos, I es grande.

13.2. Con la distancia euclídea es la varianza

Datos 1, 2, 6, media 3, $\phi = x^2$:

$$I_\phi(X) = \frac{(1-3)^2 + (2-3)^2 + (6-3)^2}{3} = \frac{4+1+9}{3} = \frac{14}{3} \approx 4.67.$$

Ese cálculo es la definición de varianza: el promedio de los desvíos al cuadrado respecto de la media. Con la I-divergencia, los mismos datos dan $I \approx 0.750$: una "varianza" medida con otra regla, que pondera menos las diferencias en valores grandes.

13.3. Con KL es la información mutua

Aquí X no es un número sino una distribución de probabilidad. Hay dos orígenes, u_1 y u_2, igual de frecuentes, y un destino Y que puede ser A o B:

Origen	$P(A)$	$P(B)$
u_1	0.9	0.1
u_2	0.1	0.9

Cada fila es una distribución condicional $p(Y \mid U = u)$, y esos son los datos X, cada uno con probabilidad 1/2. La **media** de esos datos es la distribución marginal $p(Y)$, el promedio de las filas: $(0.5, 0.5)$. El error de cada fila contra la media, con KL, es

$$0.9 \ln \frac{0.9}{0.5} + 0.1 \ln \frac{0.1}{0.5} = 0.529 - 0.161 = 0.368,$$

y por simetría lo mismo para u_2. El promedio es $I = 0.368$, que es la **información mutua** $I(U;Y)$: cuánto dice saber el origen sobre el destino. Se verifica con la fórmula clásica $H(Y) - H(Y \mid U) = 0.693 - 0.325 = 0.368$. Si los dos orígenes tuvieran el mismo reparto de destinos, las filas serían iguales a su media y $I = 0$.

13.4. Por qué importa para la tesis

Problema	ϕ	Qué se minimiza
K-means (agrupamiento por mínima varianza)	x^2	Varianza dentro de grupos
Co-agrupamiento de Dhillon et al.	KL	Pérdida de información mutua

Esa doble lectura justifica usar un solo marco, el de Bregman, para ambos problemas.

> La información de Bregman es el error que queda al usar el mejor representante (la media). Con la distancia euclídea es la varianza; con KL es la información mutua.

Parte III
Sección 2.3.3: Relación con las familias exponenciales

14. Por qué existe esta sección

Hasta ahora se dijo que la I-divergencia es la apropiada para conteos, pero eso es un argumento de sentido común: pondera el error según el tamaño de la celda. Un jurado puede preguntar por qué esa y no otra función que también pese por tamaño. La respuesta estadística de esta sección es:

> Minimizar la I-divergencia es exactamente lo mismo que maximizar la verosimilitud de un modelo de Poisson.

Eso cambia el estatus del método: deja de ser una regla de ajuste elegida a ojo y pasa a ser el ajuste de un modelo estadístico con un supuesto claro, que los conteos de cada celda son Poisson. Tiene tres consecuencias:

- **Justificación:** se elige la I-divergencia porque corresponde al modelo natural para conteos.
- **Lectura de los resultados:** un bloque deja de ser "un grupo de celdas parecidas" y es una región donde los viajes se explican con una intensidad media común. Es lo que se usa en la Sección 2.5 y en la descomposición de la divergencia.
- **Conexión con el capítulo de estadística:** el modelo de Poisson con interacción (log-lineal) es el marco para decir qué es "interacción espacio-temporal".

15. Qué es una familia exponencial

Es una colección de distribuciones que comparten una forma matemática: la normal, la Poisson, la binomial, la gamma. No hace falta la forma general. Lo que importa es que **cada una tiene un parámetro de media** μ, el valor promedio de los datos, y que la probabilidad de un dato depende de qué tan cerca está de esa media.

16. El resultado de Banerjee et al. (2005)

Existe una **correspondencia uno a uno** entre divergencias de Bregman y familias exponenciales. Para cada familia hay una ϕ, y la densidad se escribe

$$p(x \mid \mu) = \exp\{-d_\phi(x, \mu)\}\, b_\phi(x).$$

Símbolo	**Qué es**
$p(x \mid \mu)$	Probabilidad de observar x si la media verdadera es μ
$d_\phi(x, \mu)$	La divergencia entre el dato y la media
$\exp\{-d\}$	Una función que baja cuando d sube: más lejos de la media, menos probable
$b_\phi(x)$	Un factor que depende solo del dato, no de μ

La lectura es directa: un dato es probable cuando está cerca de la media, y "cerca" se mide con la divergencia de Bregman de esa familia. Cada familia tiene su propia regla de cercanía:

Familia	ϕ	Divergencia
Normal (varianza σ^2 fija)	$x^2/(2\sigma^2)$	$(x-\mu)^2/(2\sigma^2)$, la euclídea escalada
Poisson	$x \log x - x$	la I-divergencia

Esto prolonga la idea de la Sección 2.3.1, "cada ϕ corresponde a un supuesto sobre cómo varía el error": ahora el supuesto tiene nombre. La euclídea es el error normal y la I-divergencia es el error Poisson.

17. Verificación para Poisson

Si $x \sim \text{Poisson}(\mu)$, la probabilidad es $p(x \mid \mu) = e^{-\mu}\mu^x/x!$ y, tomando logaritmo,

$$\log p(x \mid \mu) = x \log \mu - \mu - \log x!.$$

La I-divergencia desarrollada es $d_I(x, \mu) = x \log x - x \log \mu - x + \mu$, así que $-d_I(x, \mu) = -x \log x + x \log \mu + x - \mu$. Sumando y restando $x \log x - x - \log x!$ se obtiene la fórmula de Poisson:

$$\log p(x \mid \mu) = -d_I(x, \mu) + \underbrace{\left(x \log x - x - \log x!\right)}_{\text{no depende de } \mu}.$$

El último paréntesis solo depende del dato, así que no influye al elegir μ.

Con números, $x = 4$ y $\mu = 3$:

- Probabilidad: $e^{-3} \cdot 3^4/4! = 0.168$, y $\log p = -1.784$.
- $d_I(4, 3) = 4 \ln(4/3) - 1 = 0.151$.
- Parte constante: $4 \ln 4 - 4 - \ln 24 = -1.633$.
- $-0.151 - 1.633 = -1.784$. ✓

18. Por qué minimizar la divergencia equivale a maximizar la verosimilitud

En la fórmula anterior, para elegir el mejor μ el término constante no importa; lo que cambia con μ es solo $-d_I(x, \mu)$. Mayor verosimilitud significa mayor $\log p$, es decir, mayor $-d_I$, es decir, menor d_I. Con $x = 4$ y dos medias candidatas:

μ	$d_I(4, \mu)$	$\log p$
3	0.151	-1.784
5	0.107	-1.740

$\mu = 5$ tiene menor divergencia y mayor verosimilitud: el orden es el mismo en las dos columnas, siempre.

19. Para una matriz completa

Si cada celda es un conteo Poisson independiente, $O_{ij} \sim \text{Poisson}(\mu_{ij})$, el logaritmo de la probabilidad conjunta es la suma de las celdas. Como la I-divergencia es aditiva por celda,

$$D_I(O \,\|\, \mu) = \sum_{i,j} d_I(O_{ij}, \mu_{ij}) = \tfrac{1}{2}\,\text{Dev}(\mu),$$

donde $\text{Dev}(\mu)$ es la **devianza** del modelo de Poisson, la medida estándar de qué tan mal ajusta un modelo a los conteos (Agresti, 2013). Aquí μ_{ij} es lo que predice el modelo para cada celda, en esta tesis la media del bloque al que pertenece; D_I mide el desajuste entre los conteos reales y esa predicción. Elegir los bloques que minimizan D_I es elegir el modelo de Poisson por bloques que mejor explica los datos.

> La I-divergencia no es una elección arbitraria: es la divergencia que corresponde al modelo de Poisson. Por eso el co-agrupamiento con I-divergencia se puede leer como el ajuste de un modelo estadístico a los conteos.

Parte IV
Sección 2.4: Co-agrupamiento de Bregman

20. Por qué existe esta sección

Hasta ahora hay dos piezas separadas: las **divergencias de Bregman** (2.3), una forma de medir el error al reemplazar un dato por un representante, y el **co-agrupamiento** (2.2), que agrupa a la vez las filas (regiones) y las columnas (intervalos de tiempo) y forma un tablero de bloques. La pregunta que las une es: ¿cómo se reconstruye la matriz a partir de los bloques y cómo se mide qué tan buena es esa reconstrucción?

> Se resume la matriz con unos pocos promedios, se reconstruye una matriz aproximada a partir de ellos y se eligen los grupos que hacen mínimo el error de la aproximación, medido con una divergencia de Bregman.

Es la sección que convierte la teoría de la 2.3 en un método concreto, el que luego usan ST-CC y la tesis.

Subsección	Pregunta que responde
2.4.1 Notación	¿Cómo se escribe un co-agrupamiento?
2.4.2 Aproximación y MBI	¿Qué promedios se conservan y cómo se reconstruye la matriz?
2.4.3 Las seis bases	¿Qué opciones hay para elegir los promedios?
2.4.4 Algoritmo	¿Cómo se encuentran los grupos?

Estas notas cubren 2.4.1 y 2.4.2, que son las que más cuestan.

21. Ejemplo que se usa

Una matriz de 4 regiones por 4 intervalos, agrupadas de dos en dos:

$$O = \begin{pmatrix} 12 & 8 & 3 & 1 \\ 8 & 12 & 1 & 3 \\ 2 & 2 & 10 & 6 \\ 2 & 2 & 6 & 10 \end{pmatrix}.$$

Las regiones r_1, r_2 forman el grupo 1 de filas y r_3, r_4 el grupo 2. Los intervalos t_1, t_2 forman el grupo 1 de columnas y t_3, t_4 el grupo 2. Es un tablero de 2×2 bloques.

22. 2.4.1 Notación

22.1. Las funciones ρ y τ

ρ asigna cada fila a un grupo de filas: $\rho(r_1) = \rho(r_2) = 1$ y $\rho(r_3) = \rho(r_4) = 2$. τ hace lo mismo con las columnas. Un co-agrupamiento es el par (ρ, τ), y K_R y K_T son cuántos grupos hay de cada tipo (aquí 2 y 2).

22.2. Los bloques

I_g es el conjunto de filas del grupo g, J_h el de columnas del grupo h, y $B_{gh} = I_g \times J_h$ es el bloque que forman. Por ejemplo, B_{11} son las cuatro celdas de arriba a la izquierda.

22.3. La lectura probabilística

Para escribir los promedios de forma compacta, Banerjee et al. eligen una celda de la matriz **al azar** y llaman U a la fila elegida y V a la columna elegida (cada una uniforme), $Z = O_{UV}$ al valor de esa celda (una variable aleatoria), y $\hat{U} = \rho(U)$, $\hat{V} = \tau(V)$ a los grupos de la fila y la columna elegidas. Con eso, cada promedio es una *esperanza condicional*: el promedio de Z restringido a lo que se indica.

Notación	Significado	En el ejemplo
$\mathrm{E}[Z]$	Promedio de toda la matriz	$88/16 = 5.5$
$\mathrm{E}[Z \mid U = i]$	Media de la fila i	Fila r_1: $24/4 = 6$
$\mathrm{E}[Z \mid \hat{U} = g, \hat{V} = h]$	Media del bloque B_{gh}	B_{11}: $40/4 = 10$

No hay nada profundo aquí: es una forma de escribir "promedio de las celdas que cumplen esta condición" con una sola notación. La ventaja es que la información de Bregman y la media como mejor representante (2.3.2) se aplican directamente.

Medias de los cuatro bloques del ejemplo:

Bloque	Celdas	Media
B_{11}	12, 8, 8, 12	10
B_{12}	3, 1, 1, 3	2
B_{21}	2, 2, 2, 2	2
B_{22}	10, 6, 6, 10	8

23. 2.4.2 Aproximación y principio de mínima información de Bregman

23.1. La pregunta

Un co-agrupamiento resume la matriz con un conjunto de promedios. Hay que decidir cuáles promedios conservar y cómo reconstruir la matriz a partir de ellos. Banerjee et al. responden con dos elementos.

23.2. Elemento 1: la base $\mathcal{C}$

Es la lista de promedios que se conservan. Cada elemento es un conjunto de variables tomadas de $\{U, V, \hat{U}, \hat{V}\}$. La base $\{\hat{U}, \hat{V}\}$ conserva la media de cada bloque (es la más simple, C2). La base $\{\hat{U}\}, \{\hat{V}\}$ conserva solo la media de cada grupo de filas y la de cada grupo de columnas, sin saber qué pasa en cada bloque (C1). Hay seis bases en total, que se ven en 2.4.3.

23.3. Elemento 2: el principio MBI

Con los promedios fijados hay muchas matrices que los respetan, y hay que elegir una. La regla es: entre todas las matrices que conservan los promedios de la base, se elige la de **menor información de Bregman**. Recuerda de la 2.3.2 que la información de Bregman mide cuánta variabilidad hay. Elegir la de menor información es elegir la matriz más simple compatible con los promedios: no inventa estructura que los promedios no exigen. Es el mismo espíritu que la máxima entropía, y con la I-divergencia o KL coinciden.

23.4. Cómo se ve en el ejemplo

Base C2 (media de cada bloque): la matriz más simple compatible rellena cada bloque con su media,

$$\hat{O} = \begin{pmatrix} 10 & 10 & 2 & 2 \\ 10 & 10 & 2 & 2 \\ 2 & 2 & 8 & 8 \\ 2 & 2 & 8 & 8 \end{pmatrix}.$$

Base C1 (solo media por grupo de filas y por grupo de columnas): el MBI con I-divergencia da la fórmula multiplicativa $\mathrm{E}[Z \mid \hat{U}]\,\mathrm{E}[Z \mid \hat{V}]/\mathrm{E}[Z]$. Las medias por grupo de filas son 6 y 5, las de columnas son 6 y 5, y $\mathrm{E}[Z] = 5.5$:

Bloque	Cálculo	Aproximación
B_{11}	$6 \cdot 6/5.5$	6.55
B_{12}	$6 \cdot 5/5.5$	5.45
B_{21}	$5 \cdot 6/5.5$	5.45
B_{22}	$5 \cdot 5/5.5$	4.55

Es el modelo de independencia: las medias de fila y de columna se multiplican. Esta matriz respeta las medias por grupo (la media del grupo 1 de filas es $(6.55 + 5.45)/2 = 6$) pero no ve que el bloque B_{11} es mucho más alto que B_{12}. La base elige qué estructura puede capturar la aproximación: C2 captura diferencias entre bloques; C1 solo captura efectos de fila y de columna por separado.

23.5. Propiedades que se mencionan, sin demostrar

La solución MBI, $\hat{Z}_{\mathcal{C}}$, es además la mejor aproximación en divergencia esperada entre las de su misma forma, y cumple una propiedad pitagórica que se usa en la Sección 2.5 para descomponer la divergencia.

24. La función objetivo

$$(\rho^*, \tau^*) = \arg\min_{\rho,\tau} \mathrm{E}\big[d_\phi\big(Z, \hat{Z}_{\mathcal{C}}(\rho, \tau)\big)\big].$$

Se lee: entre todos los co-agrupamientos posibles, se elige el que hace mínimo el error promedio entre la matriz real y su aproximación. Con medida uniforme es proporcional a $\sum_{i,j} d_\phi(O_{ij}, \hat{O}_{ij})$, la suma de errores celda por celda, como en la 2.3.1.

Con números (base C2, I-divergencia, los grupos del ejemplo):

Bloque	Media	Suma de d_I celda por celda
B_{11}	10	0.805
B_{12}	2	1.047
B_{21}	2	0 (todas valen 2)
B_{22}	8	1.011
Total		≈ 2.86

El algoritmo busca la partición que haga ese total lo más chico posible.

> Un co-agrupamiento resume la matriz con promedios (la base). El MBI reconstruye la matriz más simple que respeta esos promedios. Se elige la partición cuya reconstrucción se parece más a los datos, medido con una divergencia de Bregman.

25. 2.4.3 Las seis bases

25.1. Por qué existe esta subsección

En la 2.4.2 se vio que hay que decidir qué promedios conservar (la base), y que cada opción produce una aproximación distinta. Banerjee et al. demuestran que en dos dimensiones solo hay **seis bases distintas**: las demás son triviales (no resumen nada) o redundantes (equivalen a alguna de estas). Cada base responde a la pregunta: además de dividir en bloques, ¿cuánto detalle de la matriz se quiere conservar?

25.2. Cómo leer la notación

U y V son una fila y una columna **individuales**; $\hat{U}$ y $\hat{V}$ son el **grupo** de esa fila y de esa columna. Un conjunto como $\{\hat{U}, \hat{V}\}$ significa "conserva la media de cada pareja (grupo de filas, grupo de columnas)", es decir, cada bloque; $\{U\}$ significa "conserva la media de cada fila individual".

25.3. Las seis bases en palabras

Base	Qué conserva	Qué dice la aproximación	Familia
C1	Media por grupo de filas y por grupo de columnas	Independencia entre filas y columnas, sin bloques	Sin bloques
C2	Media de cada bloque	Todas las celdas de un bloque valen lo mismo	Bloques
C3	Bloque y cada fila	Bloque, corregido por cuánto más grande es la fila que su grupo	Bloques y volumen de fila
C4	Bloque y cada columna	Bloque, corregido por el volumen de la columna	Bloques y volumen de columna
C5	Bloque, cada fila y cada columna	Bloque, corregido por el volumen de la fila y de la columna	Bloques y ambos volúmenes
C6	Cada fila dentro de cada grupo de columnas, y cada columna dentro de cada grupo de filas	Perfiles internos de cada bloque	Más fino

25.4. La idea de las fórmulas con I-divergencia

La más fácil de leer es C5:

$$\hat{O}_{ij} = \frac{\mathrm{E}[Z|U]\,\mathrm{E}[Z|V]\,\mathrm{E}[Z|\hat{U},\hat{V}]}{\mathrm{E}[Z|\hat{U}]\,\mathrm{E}[Z|\hat{V}]}.$$

Reagrupada:

$$\hat{O}_{ij} = \underbrace{\mathrm{E}[Z|\hat{U},\hat{V}]}_{\text{media del bloque}} \times \underbrace{\frac{\mathrm{E}[Z|U]}{\mathrm{E}[Z|\hat{U}]}}_{\text{factor de fila}} \times \underbrace{\frac{\mathrm{E}[Z|V]}{\mathrm{E}[Z|\hat{V}]}}_{\text{factor de columna}}.$$

Cada factor compara una fila (o columna) con *su grupo*: si una región tiene el doble de viajes que el promedio de su grupo, el factor de fila es 2. La aproximación toma la media del bloque y la escala por esos dos factores. Por eso C5 distingue entre "esta región es más grande" y "esta región tiene un patrón distinto". C3 aplica solo el factor de fila, C4 solo el de columna y C2 ninguno.

25.5. Ejemplo: la diferencia entre C2 y C5

Para verla hace falta una matriz donde las filas tengan distinto volumen. Una matriz con un solo bloque (todo en un grupo):

$$\begin{pmatrix} 2 & 4 \\ 6 & 12 \end{pmatrix}.$$

La fila 2 tiene el triple de viajes que la fila 1, con el mismo perfil. Las medias de fila son 3 y 9, las de columna 4 y 8, y la global 6.

Con C2 (media del bloque) todas las celdas valen 6. La I-divergencia suma $d(2,6) = 1.80$, $d(4,6) = 0.38$, $d(6,6) = 0$ y $d(12,6) = 2.32$, es decir, $\approx \mathbf{4.50}$.

Con C5, con un solo bloque la fórmula queda $\mathrm{E}[Z|U]\,\mathrm{E}[Z|V]/\mathrm{E}[Z]$. Celda $(1,1)$: $3 \cdot 4/6 = 2$; $(1,2)$: $3 \cdot 8/6 = 4$; $(2,1)$: $9 \cdot 4/6 = 6$; $(2,2)$: $9 \cdot 8/6 = 12$. Reproduce la matriz exacta: pérdida **0**.

La matriz es un patrón único multiplicado por el volumen de cada fila y de cada columna. C2 lo ve como un error grande; C5 lo explica entero porque descuenta el volumen. Esta es la diferencia que la tesis usa para justificar C5: las diferencias de volumen entre regiones no son interacción espacio-temporal.

25.6. Casos particulares conocidos

Base y divergencia	Método conocido
C2 + euclídea	Co-agrupamiento clásico de bloques constantes (primer residuo de Cho et al., 2004)
C6 + euclídea	Residuo cuadrático mínimo de Cho et al. (segundo residuo); sobre él se construye el BCC_MSSR de Wu et al. (2022)
C5 + I-divergencia	ITCC de Dhillon et al. (2003): con distribuciones conjuntas la I-divergencia es KL, y minimiza la pérdida de información mutua

Esto respalda la idea de la 2.3: un solo marco generaliza métodos que parecían distintos.

25.7. La nota sobre C6

C6 aparece en dos contextos con la misma estructura y distinta combinación. Con la euclídea combina las marginales del bloque *sumando* (el residuo de Cho). Con la I-divergencia las combina *multiplicando* (la prueba de independencia dentro del bloque de la Sección 2.5). Es la misma idea con dos álgebras: la euclídea trabaja con diferencias y la I-divergencia con razones, igual que en la 2.3.1 la euclídea mide diferencias y la I-divergencia pondera por tamaño.

> Las seis bases son seis niveles de detalle para reconstruir la matriz. C2 conserva solo bloques; C5 añade el volumen de cada fila y columna; C6 conserva más estructura interna. Cada una, con una divergencia, reproduce un método clásico.

26. 2.4.4 Algoritmo

26.1. Por qué existe esta subsección

Ya se sabe qué se quiere: la partición (ρ, τ) que haga mínimo el error entre la matriz y su aproximación. Falta **cómo encontrarla**. La tentación es probar todas las particiones, pero es inviable: solo asignar 100 filas a 5 grupos admite unas $5^{100} \approx 10^{70}$ posibilidades, sin contar las columnas.

El texto lo dice con un término técnico: el problema es **NP-difícil**, por reducción desde K-means. Significa que no se conoce un método eficiente que garantice la mejor partición. Por eso Banerjee et al. proponen un método que no garantiza el óptimo pero llega a una buena solución rápido: la **minimización alternante**.

26.2. La idea

Es la misma que K-means (2.3.2): alternar entre dos pasos sencillos. Con los **grupos fijos**, calcular los mejores promedios (los de la base); con los **promedios fijos**, mejorar los grupos.

Aquí hay dos tipos de grupos (filas y columnas), así que se alterna entre tres cosas: promedios, filas y columnas.

26.3. Los pasos

Paso	Qué hace	En palabras
1	Inicializa ρ y τ al azar	Empieza con grupos cualesquiera
2	Calcula los estadísticos de la base y la aproximación $\hat{O}$	Con los grupos actuales, calcula los promedios y reconstruye la matriz
3	Reasigna cada fila al grupo g que minimiza $\sum_j d_\phi(O_{ij}, \hat{O}_{ij})$ calculada como si i perteneciera a g; recalcula los estadísticos	Cada fila se muda al grupo que mejor la explica
4	Repite el paso 3 con las columnas, con ρ fija	Lo mismo para las columnas
5	Si la reducción de la divergencia es menor que ε, termina; si no, vuelve al paso 3	Para cuando casi no mejora

El paso 3 es el que cuesta. Para decidir dónde va la fila i, se prueba cada grupo g y se calcula el error de la fila si estuviera ahí, usando los promedios de ese grupo. Se elige el grupo de menor error. Es el equivalente a "asignar cada punto al centroide más cercano" de K-means, solo que el "centroide" ahora es un conjunto de promedios por bloque.

26.4. Ejemplo con la matriz 4×4

Matriz de la 2.4.2, base C2 e I-divergencia:

$$O = \begin{pmatrix} 12 & 8 & 3 & 1 \\ 8 & 12 & 1 & 3 \\ 2 & 2 & 10 & 6 \\ 2 & 2 & 6 & 10 \end{pmatrix}.$$

Paso 1. Se supone que τ ya es correcta (columnas 1, 2 y 3, 4) y que ρ empieza mal: las filas r_1, r_2, r_3 en el grupo 1 y r_4 sola en el grupo 2. El error total de esa partición es $\approx$ **15.6**.

Paso 2. Promedios de los bloques:

Bloque	Celdas	Media
Grupo 1, columnas 1–2	12, 8, 8, 12, 2, 2	7.33
Grupo 1, columnas 3–4	3, 1, 1, 3, 10, 6	4
Grupo 2, columnas 1–2	2, 2	2
Grupo 2, columnas 3–4	6, 10	8

Paso 3. Se mira la fila $r_3 = (2, 2, 10, 6)$. Si se queda en el grupo 1, se la compara con $(7.33, 7.33, 4, 4)$ y el error es $2.73 + 2.73 + 3.16 + 0.43 \approx$ **9.07**. Si pasa al grupo 2, se la compara con $(2, 2, 8, 8)$ y el error es $0 + 0 + 0.23 + 0.27 \approx$ **0.51**. Se muda al grupo 2. Las filas r_1 y r_2 prefieren claramente el grupo 1 (error $\approx$ **3** frente a ≈ 24) y r_4 se queda donde está. La partición de filas queda $\{r_1, r_2\}, \{r_3, r_4\}$: la correcta, con error total $\approx$ **2.86**.

Paso 4. Con ρ ya correcta, ninguna columna mejora cambiando de grupo.

Paso 5. El error bajó de 15.6 a 2.86 en el paso 3 y en el paso 4 no cambió. La mejora es menor que ε y el algoritmo termina.

26.5. Por qué converge

- **Cada paso no aumenta el error.** Al recalcular los promedios, la media es el mejor representante de cada grupo (esto es la 2.3.2). Al reasignar filas, cada una elige el grupo que menos error le da.
- **Hay un número finito de particiones.** Como el error nunca sube y no hay infinitos estados, el algoritmo no puede dar vueltas para siempre: se detiene en un número finito de iteraciones.

26.6. La limitación: mínimo local

Converger no significa llegar a la mejor solución. El algoritmo termina en un **mínimo local**: una partición que no mejora cambiando las filas, las columnas o los promedios, pero que podría ser peor que otra partición lejana. Es como un excursionista que baja una montaña por el camino más empinado: llega a un valle, pero puede haber otro valle más profundo al otro lado.

Tres precauciones que menciona el texto:

1. **Varias inicializaciones.** Se ejecuta con muchos arranques al azar y se conserva el mejor resultado. Liu et al. usaron 200.
2. **Búsqueda local.** Cho et al. muestran que, después de converger, mover filas o columnas de una en una puede seguir bajando el error. El algoritmo básico mueve todas a la vez (por lotes), y por eso hay mejoras que se le escapan.
3. **Costo.** Cada iteración cuesta $O\big(mn(K_R + K_T)\big)$ operaciones: proporcional al tamaño de la matriz por el número de grupos.

Como probar todas las particiones es imposible, se alterna entre calcular promedios y reasignar filas y columnas. Cada paso baja el error, así que converge, pero a un mínimo local, por lo que se repite con muchos arranques.

Parte V
Sección 2.5: La I-divergencia y el modelo de Poisson

27. Por qué existe esta sección

El marco de Bregman (2.4) funciona con cualquier divergencia. Pero la tesis usa una sola, la I-divergencia, con conteos de viajes. Esta sección particulariza todo a ese caso y obtiene tres cosas que solo existen ahí:

1. **Fórmulas explícitas** para las bases C2, C5 y C6 con totales de fila, columna y bloque.
2. **Lectura estadística:** cada base es un modelo de Poisson concreto, y tres de ellas están anidadas (C2 $\subset$ C5 $\subset$ C6).
3. **Una descomposición** de la divergencia en tres términos con interpretación propia, que justifica el estadístico de heterogeneidad G^2 del método propuesto.

La 2.4 dice cómo se hace el co-agrupamiento; la 2.5 dice qué significa lo que se mide y por qué G^2 es la herramienta adecuada para buscar patrones locales.

Subsección	**Pregunta**
2.5.1 Tres bases en notación matricial	¿Cómo se calculan C2, C5 y C6 con totales?
2.5.2 Modelos log-lineales de Poisson	¿Qué modelo estadístico es cada base?
2.5.3 Descomposición	¿De qué partes se compone el error?
2.5.4 Escala	¿Importa si se usan conteos o promedios?

Estas notas cubren toda la sección 2.5.

28. 2.5.1 Tres bases en notación matricial

28.1. Los totales que se necesitan

Con la matriz de conteos O de 4×4 de la 2.4.2:

Símbolo	**Significado**	**Ejemplo**
$O_{i\cdot}$	Total de la fila i	$r_1 = 24$, $r_3 = 20$
$O_{\cdot j}$	Total de la columna j	$c_1 = 24$, $c_3 = 20$
N	Total general	88
$O_{g\cdot}, O_{\cdot h}$	Total del grupo de filas g y del grupo de columnas h	48 y 40
N_{gh}	Total del bloque	40, 8, 8, 32
O_{ih}	Total de la fila i *dentro* del grupo de columnas h	r_1 en columnas 1–2: 20
O_{gj}	Total de la columna j *dentro* del grupo de filas g	c_1 en filas 1–2: 20

Son los mismos promedios de la 2.4, escritos como sumas (promedio por número de celdas).

28.2. Las tres fórmulas

$$\hat{O}_{ij}^{\mathrm{C2}} = \frac{N_{gh}}{|I_g||J_h|}, \qquad \hat{O}_{ij}^{\mathrm{C5}} = \frac{O_{i\cdot}O_{\cdot j}N_{gh}}{O_{g\cdot}O_{\cdot h}}, \qquad \hat{O}_{ij}^{\mathrm{C6}} = \frac{O_{ih}O_{gj}}{N_{gh}}.$$

Base	Lectura
C2	Todas las celdas del bloque valen la media del bloque
C5	Reparte el total del bloque en proporción al volumen global de cada región y cada intervalo
C6	Trata cada bloque como una tabla de contingencia *independiente*: lo esperado si filas y columnas no estuvieran asociadas *dentro del bloque*

Con el ejemplo $\begin{pmatrix} 2 & 4 \\ 6 & 12 \end{pmatrix}$ de un solo bloque, C5 da en la celda $(1,1)$: $6 \cdot 8 \cdot 24/(24 \cdot 24) = 2$, el dato exacto.

28.3. C5 y la información mutua

$$D_I(O \,\|\, \hat{O}^{\mathrm{C5}}) = N\,\big[I(R;T) - I(\hat{R};\hat{T})\big].$$

Con C5, el error de la aproximación es **la información mutua que se pierde** al agrupar las regiones y los intervalos (R, T son filas y columnas; $\hat{R}$, $\hat{T}$ sus grupos), multiplicada por N. Es la conexión con Dhillon (ITCC) vista en la 2.3: la información de Bregman con KL es información mutua.

28.4. C6 y la prueba de independencia

$$D_I(O \,\|\, \hat{O}^{\mathrm{C6}}) = \tfrac{1}{2}\sum_{g,h} G^2_{gh}, \qquad G^2_{gh} = 2 \sum_{(i,j)\in B_{gh}} O_{ij} \log \frac{O_{ij} N_{gh}}{O_{ih} O_{gj}}.$$

G^2 es el estadístico de razón de verosimilitud de la **prueba de independencia** de una tabla de contingencia, el que se usa en estadística clásica para ver si dos variables están asociadas. También se escribe $G^2_{gh} = 2N_{gh}\hat{I}_{gh}(R;T)$: la información mutua dentro del bloque, escalada por su masa.

Ejemplo con un bloque con patrón. Sea el bloque $\begin{pmatrix} 6 & 2 \\ 2 & 6 \end{pmatrix}$. Los totales de fila y de columna son 8 y $N = 16$, así que lo esperado bajo independencia es $8 \cdot 8/16 = 4$ en cada celda. Pero los datos son 6, 2, 2, 6: hay asociación (la diagonal pesa más).

$$G^2 = 2\big[2 \cdot 6 \ln 1.5 + 2 \cdot 2 \ln 0.5\big] = 2[4.866 - 2.773] \approx \mathbf{4.19}.$$

Un bloque sin asociación (todas las celdas valen 4) daría $G^2 = 0$. Se verifica con la I-divergencia: $d(6,4) = 0.433$ y $d(2,4) = 0.614$, y $2(0.433 + 0.614) = 2.093 = G^2/2$.

> G^2 mide cuánta asociación entre regiones y horarios queda dentro del bloque. Este es el patrón local que busca la tesis.

29. 2.5.2 Equivalencia con modelos log-lineales de Poisson

29.1. De dónde viene

En la 2.3.3 se vio que minimizar la I-divergencia es maximizar la verosimilitud de Poisson. Falta saber **qué modelo** de Poisson. Cada base define uno, para las medias μ_{ij} de las celdas:

Base	Modelo	Lectura
C2	$\log \mu_{ij} = \lambda_{\rho(i)\tau(j)}$	Un nivel por bloque
C5	$\log \mu_{ij} = \alpha_i + \beta_j + \lambda_{\rho(i)\tau(j)}$	Un nivel por bloque, más un efecto de fila y uno de columna
C6	$\log \mu_{ij} = \alpha_{i,\tau(j)} + \beta_{\rho(i),j}$	El efecto de cada fila cambia según el grupo de columnas, y el de cada columna según el grupo de filas

Un modelo **log-lineal** suma efectos en el logaritmo, y al deshacer el logaritmo los efectos se **multiplican**. Por eso C5 es "media del bloque × factor de fila × factor de columna": es exactamente la fórmula reagrupada de la 2.4.3. Aquí se ve de dónde sale esa forma.

29.2. Las aproximaciones son los estimadores de máxima verosimilitud

En un modelo log-lineal de Poisson, las medias ajustadas deben reproducir los totales observados de cada término del modelo. Esos totales son justamente los promedios que conserva cada base. Entonces las fórmulas de la 2.5.1 **son** las estimaciones de máxima verosimilitud de esos modelos. Eso cierra el círculo con el principio MBI de la 2.4.2: la matriz más simple que respeta los promedios es la que maximiza la verosimilitud de Poisson. El resultado de Birch garantiza que existe un único conjunto de valores ajustados que cumple el modelo y reproduce esos totales.

29.3. Modelos anidados

Para una partición fija, C2 $\subset$ C5 $\subset$ C6: cada modelo contiene al anterior como caso particular. C2 es C5 con $\alpha = \beta = 0$, y C5 es C6 reescribiendo los efectos de modo que no dependan del grupo. Es la misma cadena de la 2.4.3 (de menos a más detalle), ahora vista como modelos estadísticos.

29.4. Parámetros libres

Con $m = n = 4$ y $K_R = K_T = 2$ (la matriz del ejemplo):

Modelo	Fórmula	Valor
C2	$K_R K_T$	4
C5	$K_R K_T + (m - K_R) + (n - K_T)$	8
C6	$K_T m + K_R n - K_R K_T$	12
Saturado	mn	16

A más parámetros, más flexible el modelo y menor el error, pero más riesgo de ajustarse al ruido. La diferencia entre el saturado y C6 es $\sum(|I_g|-1)(|J_h|-1) = 4$, igual que los grados de libertad de las pruebas de independencia por bloque ($16 - 12 = 4$).

> Con I-divergencia, cada base es un modelo de Poisson: C2 un nivel por bloque, C5 añade volumen de fila y columna, C6 permite perfiles propios por bloque. Los tres están anidados, y G^2 mide la asociación que queda dentro de cada bloque.

30. 2.5.3 Descomposición de la divergencia

30.1. Por qué existe esta subsección

En la 2.5.2 se vio que C2, C5 y C6 son tres modelos anidados, de menos a más detalle. Cada uno deja un error distinto al aproximar la matriz. La pregunta que responde esta subsección es:

cuando una partición deja un error grande, ¿de qué está hecho ese error? Es la parte central de la sección, porque justifica por qué el método de la tesis mide la heterogeneidad con G^2 y no con un criterio más simple.

30.2. La descomposición

$$D_I(O\|\hat{O}^{\mathrm{C2}}) = \underbrace{D_I(\hat{O}^{\mathrm{C5}}\|\hat{O}^{\mathrm{C2}})}_{\text{(i) efectos marginales}} + \underbrace{D_I(\hat{O}^{\mathrm{C6}}\|\hat{O}^{\mathrm{C5}})}_{\text{(ii) marginales por bloque}} + \underbrace{\tfrac{1}{2}\sum_{g,h} G^2_{gh}}_{\text{(iii) interacción local}} .$$

De dónde sale la idea. Es una propiedad tipo Pitágoras. Si hay dos modelos anidados, uno simple y uno complejo, ajustados por máxima verosimilitud, el error del simple se parte en dos:

$$\text{error del simple} = \text{error del complejo} + \text{distancia entre los dos modelos.}$$

Es la misma estructura de la 2.3.2: error con s = error con la media + castigo por alejarse. Aplicada dos veces a la cadena C2 $\subset$ C5 $\subset$ C6, y sabiendo que el error de C6 es $\frac{1}{2}\sum G^2$, sale la fórmula.

30.3. Qué mide cada término

Término	Qué mide	Pregunta
(i) $D(\hat{O}^{\mathrm{C5}}\|\hat{O}^{\mathrm{C2}})$	Cuánto del error se explica solo porque unas regiones e intervalos tienen más volumen que otros	¿Es heterogeneidad real o solo diferencia de tamaño?
(ii) $D(\hat{O}^{\mathrm{C6}}\|\hat{O}^{\mathrm{C5}})$	Cuánto cambia el peso relativo de una región según el grupo de horarios (o de un intervalo según el grupo de regiones)	¿Una región se comporta distinto en bloques distintos?
(iii) $\frac{1}{2}\sum G^2_{gh}$	La asociación que queda dentro de cada bloque cuando ya se conocen sus propias marginales	¿Hay un patrón local dentro del bloque?

Ejemplo para (i): una zona de Midtown genera más viajes que una del norte de Manhattan *a cualquier hora*; eso es volumen, no interacción espacio-temporal. Ejemplo para (ii): una región que pesa más en los horarios de oficina que en los nocturnos, aunque su volumen total sea el mismo.

30.4. Dos ejemplos que aíslan los términos

Ejemplo A: todo es volumen (término i). La matriz de un solo bloque $\begin{pmatrix} 2 & 4 \\ 6 & 12 \end{pmatrix}$:

- con C2 (todas las celdas valen 6) el error es **4.50**;
- C5 la reproduce exacta, así que el error de C5 es 0;
- con un solo bloque, C6 = C5, así que (ii) = 0 y $G^2 = 0$;
- descomposición: **(i)** $= 4.50$, **(ii)** $= 0$, **(iii)** $= 0$.

La matriz parece "heterogénea" para un criterio basado en C2, pero no hay ningún patrón: es un único perfil multiplicado por el volumen de cada fila y columna.

Ejemplo B: todo es interacción local (término iii). La matriz 4×4 de la 2.4:

- C5 y C6 coinciden con C2 (las filas de un mismo grupo tienen el mismo total), por lo que (i) $= 0$ y (ii) $= 0$;
- G^2 por bloque: 1.61, 2.09, 0 y 2.02, y $\frac{1}{2}\sum G^2 = 2.86$;
- descomposición: **(i)** $= 0$, **(ii)** $= 0$, **(iii)** $= 2.86$, que es justo el error total de la 2.4.2.

Aquí todo el error es asociación dentro de los bloques: los viajes se concentran en la diagonal.

30.5. Por qué esto justifica G^2

- Un criterio basado en la constancia del bloque (el implícito en C2) mezcla los tres términos. En datos de movilidad con volúmenes muy desiguales, casi todos los bloques parecerían heterogéneos solo por el término (i): es el Ejemplo A.
- G^2 aísla el término (iii), que es lo que se busca: patrones locales de asociación.

Un bloque de Midtown no es interesante por ser grande; lo es si dentro de él ciertas regiones se activan en ciertos horarios de forma distinta al resto.

30.6. La advertencia sobre la prueba χ^2

G^2 tiene, bajo ciertas condiciones, una distribución conocida, la χ^2 con $(|I_g| - 1)(|J_h| - 1)$ grados de libertad, que permitiría calcular un valor-p. Por ejemplo, el bloque $\begin{pmatrix} 6 & 2 \\ 2 & 6 \end{pmatrix}$ tiene $G^2 = 4.19$ con 1 grado de libertad, lo que daría $p \approx 0.04$ y parecería "significativo". Pero esa lectura falla por tres razones:

1. **Conteos pequeños.** La aproximación exige conteos esperados grandes y es poco fiable en bloques con poca actividad.
2. **La partición se estima con los mismos datos que se prueban.** Se eligieron los bloques para que parezcan estructurados y después se pregunta si lo son. Eso infla la evidencia (es como elegir el mejor resultado de muchos intentos y calcular su significancia como si fuera el único).
3. **Sobredispersión.** Los conteos reales de viajes varían más de lo que predice Poisson.

Por eso la tesis usa otra forma de calibrar las pruebas.

> El error de una partición C2 se descompone en volumen (i), cambios de peso por bloque (ii) e interacción local (iii). G^2 aísla el tercero, que es el patrón que busca la tesis.

31. 2.5.4 Escala de los datos: conteos frente a promedios

31.1. Dos hechos

- **El co-agrupamiento no depende de la escala.** Por la homogeneidad de la I-divergencia (2.3.1), multiplicar O por una constante $c > 0$ multiplica el error por c y no cambia la mejor partición.
- **La interpretación estadística sí depende de ella.** La equivalencia con la devianza de Poisson solo vale si las celdas son **conteos**.

31.2. Por qué importa: promedios diarios

Si la matriz contiene promedios diarios, $O = S/D$, donde S son los conteos totales de D días, entonces $G^2(O) = G^2(S)/D$. Comparar eso con una χ^2 subestima la evidencia por un factor D.

Con números. El bloque $\begin{pmatrix} 6 & 2 \\ 2 & 6 \end{pmatrix}$ con $G^2 = 4.19$ podría venir de promedios sobre $D = 30$ días. Los conteos totales serían $\begin{pmatrix} 180 & 60 \\ 60 & 180 \end{pmatrix}$ y su G^2 sería $30 \times 4.19 \approx 126$. Con 4.19 la evidencia parece débil ($p \approx 0.04$); con 126 es abrumadora. Es el mismo patrón, pero la escala cambia por completo la lectura.

Por eso los resultados de Liu et al. (2021), que construyen la matriz con volúmenes promedio, no permiten una lectura estadística directa. La tesis construye la matriz con **conteos totales**, o hace explícito el factor de escala antes de cualquier prueba.

> Para que la lectura estadística sea válida, la matriz debe contener conteos totales, no promedios.

Parte VI
Sección 2.6: El marco ST-CC

32. Por qué existe en el capítulo 2

ST-CC es el marco de Liu et al. (2021). **No es el método de la tesis**: es el punto de partida que el método propuesto (AST-CC, Capítulo 3) refina. Para entender qué aporta AST-CC hay que saber qué hace ST-CC y dónde falla. Sus limitaciones son la motivación de la tesis.

	ST-CC	**AST-CC (la tesis)**
Qué es	El marco de Liu et al. (2021)	El método propuesto
Qué hace	Co-agrupa en tablero con BBAC y reagrupa los bloques con K-means	Parte del tablero de ST-CC y refina cada bloque con pruebas de hipótesis
Dónde está	Sección 2.6 (marco teórico)	Capítulo 3

33. Idea general de ST-CC

Dos etapas, con una matriz región × intervalo de tiempo:

1. **Co-agrupar en tablero** (con BBAC, 2.4): agrupa filas y columnas a la vez y forma bloques.
2. **Reagrupar los bloques con K-means**: junta bloques parecidos aunque no sean vecinos.

El aporte de los autores no es un algoritmo nuevo, sino la forma de combinar métodos existentes para interpretar los datos.

34. 2.6.1 Datos y matriz

- **Datos:** viajes de taxis de Nueva York (noviembre de 2017, unos diez millones), por lugar de bajada.

- **Filas:** 66 zonas de Manhattan. **Columnas:** 12 intervalos de dos horas.
- **Dos matrices de** 66×12**:** días laborables (12 días) y feriados (9 días).
- **Cada celda:** el *volumen promedio* de bajadas de esa zona en ese intervalo.

El punto delicado, visto en la 2.5.4: usar promedios no altera la partición, pero impide la lectura estadística como conteos de Poisson. Por eso AST-CC usa conteos totales.

35. 2.6.2 Primera etapa: co-agrupamiento en tablero

Decisión	**Valor**
Grupos de tiempo K_T	4 (probaron 4 a 8; el algoritmo devolvía siempre 4)
Grupos de regiones K_R	8 (laborables) y 6 (feriados), donde la curva del objetivo se estabiliza
Inicializaciones	200 por ejecución
Convergencia	umbral 10^{-6}, máximo 2000 iteraciones

Resultado: tableros de 8×4 y 6×4 bloques. En días laborables, los cuatro grupos de tiempo son madrugada, baja actividad, horario diurno y noche. Aunque el algoritmo no usa la ubicación, los grupos de regiones salen espacialmente compactos.

Los valores de K se eligen **mirando una curva**, sin criterio estadístico. Esa es una de las limitaciones que ataca la tesis.

36. 2.6.3 Segunda etapa: reagrupar los bloques

El problema: al asignar filas y columnas completas, bloques distintos tienen valores parecidos (casi toda la ciudad está tranquila de madrugada).

La solución: cada bloque se describe con **dos números**, la media y la desviación estándar de sus celdas (la media resume el nivel de actividad y la desviación, cuán dispersas están las celdas), y los 32 bloques (laborables) o 24 (feriados) se agrupan con K-means. El número de grupos se elige entre 3 y 8 con silueta y codo, y sale $K = 4$ en ambos periodos. Los cuatro grupos se leen como niveles de actividad: muy bajo, bajo, medio y alto.

Consecuencia: un grupo reúne bloques de distintas filas y columnas, así que el resultado deja de ser una rejilla regular. Los autores lo llaman co-agrupamiento *no en tablero*.

37. 2.6.4 Lectura de los resultados

- **Patrón espacial:** cómo se distribuyen los niveles de actividad sobre todas las regiones dentro de un grupo de horarios. Son a lo sumo cuatro por periodo, y su sucesión describe la dinámica del día.
- **Patrón temporal:** la secuencia de niveles que sigue un conjunto de regiones a lo largo del día. Encuentran 6 en laborables y 5 en feriados.
- **Hallazgos:** los días laborables son más dinámicos y rítmicos, los feriados más estáticos y aleatorios, y Penn Station solo alcanza actividad alta en feriados.

38. 2.6.5 Limitaciones: las que motivan la tesis

Limitación de ST-CC	Qué hace AST-CC
K-means fusiona bloques parecidos pero nunca divide uno; la heterogeneidad dentro de un bloque no se recupera	Refinamiento jerárquico: divide los bloques que lo necesitan
Los números de grupos se eligen con criterios heurísticos (curva, silueta, codo), sin interpretación estadística	Pruebas de hipótesis
Comparar bloques con media y desviación supone distribuciones semejantes, algo que habría que verificar	Modelo nulo local de cada bloque

39. 2.6.6 Base de co-agrupamiento: ST-CC y esta tesis

Esta subsección resuelve una ambigüedad en Liu et al.:

Qué dicen	Base
El nombre del algoritmo (BBAC con I-divergencia)	C2
La función objetivo que declaran (pérdida de información mutua)	C5
Lo que realmente hace su paquete de código	C2

Entonces ST-CC declara C5 pero implementa C2. Las dos dan un tablero de bloques, pero no son equivalentes. Por la descomposición de la 2.5.3, C2 mezcla el término (i) de volumen, así que tiende a agrupar regiones **por volumen**, mientras que C5 lo excluye y agrupa **por forma de perfil**.

La tesis adopta **C5**, porque el volumen no es interacción espacio-temporal y porque es lo que los autores declaran. C2 se reporta como variante en los experimentos. A partir de aquí la subsección deja de describir a Liu et al. y recoge una decisión de la tesis. Sigue pendiente confirmarla con el asesor.

ST-CC es el punto de partida: co-agrupa en tablero y reagrupa bloques con K-means. Sus tres limitaciones son exactamente lo que AST-CC resuelve en el Capítulo 3.

Parte VII

Sección 2.7: Pruebas de hipótesis para tablas de conteo

40. Por qué existe esta sección

En la 2.5 se vio que G^2 mide la interacción que queda dentro de un bloque. El método de la tesis (AST-CC) lo usa para decidir si un bloque se divide. Para eso hay que resolver tres problemas, y las secciones 2.7 y 2.8 son el kit de herramientas.

Problema	**Subsección**
¿Cómo obtener una distribución de referencia *válida* (tablas pequeñas, sobredispersión, grupos elegidos con los mismos datos)?	2.7.1 a 2.7.3, 2.7.5
¿Cómo controlar el error al hacer *muchas pruebas* (una por bloque del árbol)?	2.7.4
¿Cómo evitar que con millones de viajes *cualquier diferencia* resulte significativa?	2.7.6

La Sección 2.8 presenta SigTree, el método del que la propuesta toma la idea central: dividir con pruebas de hipótesis y detenerse cuando ninguna división es significativa. Estas notas cubren 2.7.1 a 2.7.6.

41. 2.7.1 Pruebas de independencia

41.1. Los conteos esperados

La hipótesis nula es que filas y columnas son independientes. Entonces el conteo esperado de cada celda es

$$\hat{E}_{ij} = \frac{x_{i+}\, x_{+j}}{x_{++}},$$

es decir, total de la fila por total de la columna entre el total general. Es la misma fórmula del modelo de independencia de la 2.4.

41.2. Dos estadísticos

- **Pearson:** $X^2 = \sum_{i,j} \dfrac{(x_{ij} - \hat{E}_{ij})^2}{\hat{E}_{ij}}$.
- **Razón de verosimilitud:** $G^2 = 2\sum_{i,j} x_{ij} \log \dfrac{x_{ij}}{\hat{E}_{ij}}$.

Bajo la hipótesis nula y con conteos esperados grandes, ambos siguen aproximadamente una χ^2 con $(a-1)(b-1)$ grados de libertad. La regla práctica es que la mayoría de los esperados sean al menos 5.

Con el bloque $\begin{pmatrix} 6 & 2 \\ 2 & 6 \end{pmatrix}$**:** todos los esperados valen 4 (menos de 5, ya es una señal de alerta). $X^2 = 4/4+4/4+4/4+4/4 = 4$ y $G^2 = 4.19$ (calculado en la 2.5). Son parecidos, como se espera. Con 1 grado de libertad dan $p \approx 0.046$ y $p \approx 0.041$.

41.3. Por qué la tesis prefiere G^2

1. **Conecta con Bregman:** $G^2 = 2D_I(x\|\hat{E})$ y $G^2 = 2N\hat{I}(R;T)$, la información mutua escalada por la masa. Es el mismo objeto de la 2.5.
2. **Se parte de forma exacta.** Si se agrupan filas, el G^2 de la tabla completa es igual al G^2 de la tabla colapsada más los G^2 dentro de cada grupo. Pearson no cumple esto.

Ejemplo de la propiedad 2. La tabla con filas $(8,2)$, $(8,2)$ y $(2,8)$ tiene $G^2 = 10.36$. Se agrupan las dos primeras filas, que son idénticas:

- tabla colapsada $\begin{pmatrix} 16 & 4 \\ 2 & 8 \end{pmatrix}$: $G^2 = 10.36$;
- dentro del grupo $\{r_1, r_2\}$: filas idénticas, $G^2 = 0$; la fila r_3 sola: $G^2 = 0$;
- suma: $10.36 + 0 + 0 = 10.36$. ✓

Todo lo asociado se explica con ese corte, y no queda nada dentro de los hijos. Esta es la base de la "ganancia de un corte" del Capítulo 3.

42. 2.7.2 Pruebas condicionales y p-valores por simulación

42.1. El problema de la χ^2

La χ^2 es una aproximación y falla en tablas pequeñas, que son frecuentes en bloques de poca actividad. Hace falta una prueba cuya validez no dependa del tamaño.

42.2. La idea: condicionar sobre los totales

Bajo independencia, si se fijan los totales de fila y de columna, la tabla se reparte al azar de una forma conocida (la **hipergeométrica multivariada**: la forma de repartir los conteos al azar manteniendo esos totales). Esa distribución no depende de parámetros desconocidos. El p-valor exacto es la probabilidad de obtener un estadístico al menos tan extremo como el observado. En tablas 2×2 es la prueba exacta de Fisher.

Con el mismo bloque $\begin{pmatrix} 6 & 2 \\ 2 & 6 \end{pmatrix}$ (todos los totales valen 8, $N = 16$): las tablas igual o más extremas son las que tienen 0, 1, 2, 6, 7 u 8 en la primera celda. Su probabilidad total es $1698/12\,870 \approx 0.13$.

Método	p-valor
χ^2 (aproximación)	≈ 0.04
Fisher (exacto)	$\approx \mathbf{0.13}$

La aproximación decía "significativo" y la prueba exacta dice que no hay evidencia al 5 %. Esta es la razón concreta por la que el plan insiste en no fiarse de la χ^2 en bloques chicos.

42.3. Simulación (Patefield)

Enumerar todas las tablas es inviable salvo en tablas muy pequeñas, así que se simulan B tablas con los mismos totales y se calcula

$$\hat{p} = \frac{1 + \#\{k : t_k \geq t_{\text{obs}}\}}{1 + B}.$$

El "+1" no es un arreglo arbitrario (Phipson y Smyth): la tabla observada es, bajo la nula, una realización más, y con la corrección la prueba es exacta. Consecuencias:

- el menor p-valor posible es $1/(B+1)$;
- para probar a nivel α hace falta $B \geq 1/\alpha - 1$: $B \geq 19$ para $\alpha = 0.05$ y $B \geq 99$ para $\alpha = 0.01$;
- **ejemplo:** con $B = 99$ y 4 tablas simuladas por encima del observado, $\hat{p} = (1+4)/100 = 0.05$.

42.4. Simulación secuencial (Besag y Clifford)

Si hay muchas pruebas y casi todas tienen p grande, simular B tablas en cada una desperdicia cómputo. Se simula hasta que h tablas superen al observado y se detiene. Si se detiene tras l tablas, el p-valor es h/l. Mantiene la validez y para pronto en los casos claramente no significativos.

42.5. El estadístico puede ser cualquiera

El estadístico puede ser cualquier función de la tabla, incluida una que haga una búsqueda, por ejemplo el máximo de G^2 sobre varias divisiones candidatas. El p-valor sigue siendo válido siempre que en cada tabla simulada **se repita la misma búsqueda**. Es la base del ajuste por selección de la 2.7.5 y del corte "min-P" del Capítulo 3.

43. 2.7.3 Remuestreo de réplicas independientes

43.1. Por qué hace falta otro método

La prueba condicional es exacta solo si los conteos son Poisson. Con sobredispersión no lo son. Hace falta una distribución de referencia que refleje la variabilidad real, sin suponer un modelo.

43.2. El bootstrap

La tabla observada es la suma de D réplicas independientes (los días): $x = \sum_d x_d$. El bootstrap remuestrea D días **con reemplazo** y recalcula el estadístico sobre su suma. Repetido muchas veces, aproxima la distribución del estadístico.

Ejemplo: con 12 días laborables, cada réplica del bootstrap elige 12 días al azar con reemplazo (algunos se repiten, otros no salen) y suma esas matrices diarias.

43.3. Tres detalles

1. **Debe hacerse bajo la hipótesis nula.** Aunque los datos no la cumplan, se desplazan o reescalan las réplicas para que su media sea la del nulo. Si no, la referencia incluiría el efecto que se quiere detectar y la prueba perdería potencia.
2. **Corrección con pocas réplicas.** La varianza empírica de D réplicas subestima la real por el factor $(D-1)/D$, así que las desviaciones se multiplican por $\sqrt{D/(D-1)}$.
3. **Supuesto que no se puede eludir:** las réplicas deben ser **independientes**. Dos días consecutivos con el mismo episodio de clima no lo son, y el remuestreo subestima la variabilidad.

G^2 se parte de forma exacta y conecta con Bregman, por eso se usa. La χ^2 falla en bloques pequeños ($p \approx 0.04$ frente a 0.13 exacto), así que se usan pruebas por simulación. Y como los conteos reales están sobredispersos, la referencia se obtiene remuestreando días.

44. 2.7.4 Comparaciones múltiples

44.1. El problema

El método hace **una prueba por cada bloque** del árbol. Si cada una se hace al nivel $\alpha = 0.05$, la probabilidad de equivocarse al menos una vez crece rápido con el número de pruebas M:

$$P(\text{al menos un falso rechazo}) = 1 - (1 - \alpha)^M.$$

M	Probabilidad
1	0.05
20	0.64
100	0.994

Con 20 pruebas ya es más probable equivocarse que no, aunque no haya ningún efecto real.

44.2. Dos formas de medir el error

Medida	**Qué controla**	**Ejemplo**
FWER	La probabilidad de cometer *al menos un* falso rechazo	Estricta
FDR	La *proporción esperada* de falsos rechazos entre los rechazos	Con 100 rechazos y FDR 5 %, se esperan unos 5 falsos

La FWER es más estricta. La FDR tolera algunos falsos a cambio de más potencia, y suele ser preferible cuando se exploran muchas hipótesis.

44.3. Las correcciones

- **Bonferroni:** prueba cada hipótesis al nivel α/M. Con $M = 20$ y $\alpha = 0.05$, cada prueba usa 0.0025. Controla la FWER sin supuestos, pero es **muy conservadora** cuando las pruebas están correlacionadas: las divisiones candidatas de un mismo bloque comparten casi todos sus datos, así que no son 20 pruebas independientes.
- **Min-P (Westfall y Young):** en vez de dividir α entre M, compara el menor p-valor (o el mayor estadístico) con su distribución nula *conjunta*, obtenida por simulación. Tiene en cuenta a la vez el número de pruebas y su correlación. Es la que retoma el Capítulo 3.
- **Benjamini y Hochberg:** controla la FDR ordenando los p-valores. Vale cuando las pruebas son independientes.

44.4. Pruebas jerárquicas

Cuando las hipótesis forman un árbol (la de un nodo solo tiene sentido si la del padre se rechazó), no hace falta corregir por todas las pruebas posibles, sino solo por las que se hacen. Tres antecedentes:

- **Meinshausen (2008):** de arriba abajo, con un nivel por grupo proporcional a su tamaño. Un hijo con el 60 % de las variables de su padre recibe el 60 % del nivel. Controla la FWER sobre toda la jerarquía.

- **Kimes (2017):** lo aplica al agrupamiento jerárquico, recorriendo el dendrograma desde la raíz y probando en cada nodo con simulación.
- **Yekutieli (2008):** para FDR, aplica Benjamini y Hochberg dentro de cada familia de hijos de una hipótesis rechazada.

44.5. La estructura que usa este problema

Si la independencia es cierta en un bloque, es cierta en todos sus sub-bloques: cualquier subtabla de una tabla con medias factorizadas también las tiene factorizadas. Entonces las hipótesis nulas verdaderas forman **subárboles completos**, y un falso rechazo solo puede ocurrir **por primera vez en la raíz** de uno de ellos. Por eso basta con controlar ese primer error y no el total de pruebas.

45. 2.7.5 Inferencia después de la selección

45.1. El problema del doble uso de los datos

Las garantías anteriores suponen que las hipótesis se fijan **antes** de ver los datos. En agrupamiento no es así: los grupos, y las hipótesis sobre ellos, se eligen con los mismos datos.

Gao et al. (2024) mostraron que, si los grupos se definen agrupando, una prueba clásica de diferencia de medias tiene un error de tipo I **extremadamente inflado**, y que el problema persiste aunque se usen dos conjuntos de datos independientes. La razón es que el agrupamiento **encuentra grupos distintos incluso cuando no hay estructura**. Si se generan datos de puro ruido, se agrupan en dos y se prueba si los grupos difieren, la prueba casi siempre sale significativa.

45.2. Tres remedios

Enfoque	Cómo funciona	Límite
1. Incluir la selección en la simulación	En cada réplica nula se repite el procedimiento de selección completo	El p-valor vale para la nula *global*, no para hipótesis más específicas
2. Inferencia selectiva	Se calcula el p-valor condicionando al evento de que el procedimiento produjo esos grupos (Gao 2024, Watanabe 2021)	Garantías formales, pero casi siempre para datos gaussianos y costoso
3. División de cada observación (count splitting)	Ver abajo	Falla con sobredispersión

45.3. Count splitting (Neufeld et al., 2024)

Cada conteo se divide en dos partes, $x = x^{(1)} + x^{(2)}$, con $x^{(1)} \mid x \sim \text{Binomial}(x, \varepsilon)$. Si $x \sim \text{Poisson}(\mu)$, las dos partes son **independientes** y Poisson, con medias $\varepsilon\mu$ y $(1-\varepsilon)\mu$. La estructura se elige con $x^{(1)}$ y se prueba con $x^{(2)}$, como si se hubiera fijado de antemano.

Ejemplo: una celda con $\mu = 10$ y $\varepsilon = 0.5$ produce $x^{(1)} \sim \text{Poisson}(5)$ y $x^{(2)} \sim \text{Poisson}(5)$, independientes. Se elige el corte con la primera mitad y se prueba con la segunda.

Es lo que distingue este enfoque de dividir las *filas* en dos grupos de datos, que no funciona según Gao: aquí cada conteo se parte, no cada fila. Pero si los conteos están sobredispersos, las dos partes dejan de ser independientes y la garantía se debilita. *Data thinning* generaliza la idea a otras familias.

46. 2.7.6 Tamaño de efecto y sobredispersión

46.1. Tamaño de efecto: el problema de los millones de viajes

Con muestras grandes, una prueba detecta desviaciones mínimas. Como $G^2 = 2N\hat{I}(R;T)$, si la información mutua poblacional es positiva, aunque sea ínfima, G^2 crece **proporcional a** N y el p-valor tiende a 0.

Ejemplo: con $\hat{I} = 0.001$ nats, $G^2 = 2$ con $N = 1\,000$, pero $G^2 = 2\,000$ con $N = 1\,000\,000$. Misma asociación diminuta; con un millón de viajes es "altamente significativa". Los autores de SigTree reconocen este fenómeno como limitación.

La solución es acompañar la significancia con una medida de tamaño de efecto que no crezca con N:

Medida	**Fórmula**	**Rango**
Información mutua por observación	$\hat{I} = G^2/(2N)$ (nats)	Conecta con la función objetivo
V de Cramér	$\sqrt{X^2/(N\,\text{mín}(a-1, b-1))}$	0 (independencia) a 1 (asociación perfecta)

Con números. El bloque $\begin{pmatrix} 6 & 2 \\ 2 & 6 \end{pmatrix}$: $X^2 = 4$, $N = 16$, mín $= 1$, así que $V = \sqrt{4/16} = 0.5$ e $\hat{I} = 4.19/32 = 0.131$. Multiplicado por 100, $\begin{pmatrix} 600 & 200 \\ 200 & 600 \end{pmatrix}$: $G^2 = 419$ (100 veces mayor), pero $V = 0.5$ e $\hat{I} = 0.131$ **iguales**. La significancia explota con N; el tamaño de efecto no.

46.2. El sesgo de la información mutua empírica

Aunque la población sea independiente, G^2 sigue una χ^2 con $\nu = (a-1)(b-1)$ grados de libertad, cuya media es ν. Entonces $\mathrm{E}[\hat{I}] \approx \nu/(2N) > 0$. Es el sesgo que corrige Miller y Madow para estimadores de información mutua.

Tabla	ν	N	Sesgo esperado de $\hat{I}$
2×2	1	100	0.005
5×5	16	100	0.08

Un umbral sobre $\hat{I}$ sin corregir favorecería a las tablas con pocas observaciones y muchas celdas, porque tendrían un $\hat{I}$ "alto" solo por azar.

46.3. Sobredispersión

Poisson impone que la varianza sea igual a la media. En datos reales es mayor, $\text{Var} = \varphi\mu$ con $\varphi > 1$, porque los eventos no son independientes: el día de la semana, el clima, eventos puntuales. Entonces X^2 y G^2 se **inflan por el factor** φ y la prueba rechaza demasiado.

Corrección por cuasi-verosimilitud (ajusta la varianza sin suponer una distribución completa): dividir el estadístico entre una estimación de φ (por ejemplo, el cociente de Pearson entre sus grados de libertad).

Ejemplo: con $\varphi = 4$, un estadístico de 8 con 1 grado de libertad ($p \approx 0.005$) se corrige a 2 ($p \approx 0.16$). Pasa de "muy significativo" a "no significativo".

46.4. Funciones de varianza

Un único φ supone varianza proporcional a la media. Hay formas más generales Var $= V(\mu)$:

- **Binomial negativa:** $V(\mu) = \mu + \mu^2/k$. La sobredispersión crece con la media. Con $k = 50$: $\mu = 10$ da varianza 12 ($\varphi = 1.2$), pero $\mu = 100$ da 300 ($\varphi = 3$).
- **Ley de potencia de Taylor:** $V(\mu) = a\mu^b$, que contiene como casos particulares Poisson ($a = b = 1$) y φ constante ($b = 1$).

46.5. El límite de todos estos modelos

Todas describen la varianza de **cada celda por separado**. Cuando la variabilidad viene de factores que actúan sobre muchas celdas a la vez (el clima de un día), las celdas dejan de ser independientes entre sí, y ningún modelo de varianza por celda lo captura. Si hay réplicas independientes (los días), la correlación se reproduce **remuestreando** (el bootstrap de la 2.7.3) en lugar de modelarla.

> Con muchas pruebas el error se acumula (64 % con 20), y como los bloques de un árbol están anidados basta con controlar el primer rechazo falso. Elegir grupos con los mismos datos infla el error y se corrige repitiendo la selección en la simulación o partiendo cada conteo. Con millones de viajes todo es significativo, así que se exige además un tamaño de efecto corregido por sesgo. La sobredispersión infla los estadísticos y se corrige remuestreando días.

Parte VIII
Sección 2.8: SigTree

47. Por qué existe esta sección

SigTree (Hu et al., 2025) es el método del que la propuesta toma su idea central: **construir una partición con pruebas de hipótesis y detenerse cuando ninguna división es significativa**. Importa por una razón concreta. En ST-CC (2.6) el número de grupos se elige mirando una curva, sin criterio estadístico. SigTree no necesita fijar el número de grupos: tiene un solo parámetro, el nivel α, con interpretación estadística clara. Eso es justo lo que busca la tesis.

La sección tiene dos funciones: explica cómo funciona SigTree y deja claro qué hay que adaptar para trasladarlo al problema de la tesis (bloques de una matriz de conteos en vez de muestras con atributos categóricos). Las herramientas de la 2.7 son las piezas con las que se hace esa adaptación.

47.1. Antecedente: CHAID

Usar pruebas de hipótesis para decidir divisiones de un árbol no es nuevo. **CHAID** (Kass, 1980) lo hace en el caso **supervisado**: elige cada división con una prueba χ^2 entre la división candidata y la variable de clase. SigTree traslada la idea al caso **no supervisado**, donde no hay variable de clase.

48. 2.8.1 Divisiones candidatas y pseudo-clases

El escenario. n muestras descritas por m atributos categóricos (el atributo q con k_q categorías).

La división candidata. En cada nodo, cada categoría c de cada atributo j define una división: separa las muestras con valor c en el atributo j de las que no. Se representa con una variable binaria $Z = \mathbb{1}[x_j = c]$.

El problema: no hay variable de clase contra la cual probar la división. **La solución:** cada uno de los otros $m - 1$ atributos hace de **pseudo-clase**, es decir, de etiqueta provisional.

- **Hipótesis nula de cada prueba:** Z es independiente del atributo q.
- **Hipótesis nula global:** Z es independiente de todos los demás atributos.
- **Intuición:** si las muestras del nodo no tienen estructura de grupos, ninguna división candidata estará asociada con la mayoría de las pseudo-clases. Si sí hay grupos, una buena división separará a la vez muchos atributos.

49. 2.8.2 Estadístico y criterio de división

Para cada par (división Z, atributo $q \neq j$):

1. se construye la tabla de contingencia $2 \times k_q$;
2. se calcula el estadístico de Pearson $X^2(Z, q)$; en tablas 2×2 con algún esperado menor que 5 se aplica la **corrección de Yates**, un ajuste que evita sobrestimar el estadístico con conteos pequeños;
3. se suman todos los atributos:

$$X^2(Z) = \sum_{q \neq j} X^2(Z, q), \qquad \mathrm{gl}(Z) = \sum_{q \neq j} (k_q - 1);$$

4. el p-valor se obtiene de la χ^2 con $\mathrm{gl}(Z)$ grados de libertad, suponiendo que las pruebas individuales son independientes;
5. en cada nodo se elige la división de **menor p-valor**.

49.1. Ejemplo numérico

Un nodo con 100 muestras y tres atributos binarios A, B y C. Se prueba la división $Z = \mathbb{1}[A = 1]$: 50 muestras tienen $A = 1$ y 50 no.

Pseudo-clase	Tabla $Z\times$ atributo	Esperados	X^2
B	$\begin{pmatrix} 40 & 10 \\ 10 & 40 \end{pmatrix}$	25 en cada celda	$4 \cdot 15^2/25 = \mathbf{36}$
C	$\begin{pmatrix} 30 & 20 \\ 20 & 30 \end{pmatrix}$	25 en cada celda	$4 \cdot 5^2/25 = \mathbf{4}$

La suma es $X^2(Z) = 36 + 4 = 40$ con $\mathrm{gl} = 1 + 1 = 2$. El p-valor de la χ^2 con 2 grados de libertad es $e^{-20} \approx 2 \cdot 10^{-9}$, muy pequeño. La división $A = 1$ está fuertemente asociada con B y débilmente con C, y la suma lo recoge. SigTree compara este p-valor con el de las demás candidatas y se queda con la menor.

50. 2.8.3 Criterios de parada

La división elegida solo se aplica si su p-valor es menor o igual que un nivel ajustado

$$\alpha^* = \frac{\alpha}{|Q|},$$

donde $|Q|$ es el número total de categorías de todos los atributos. Es una corrección de Bonferroni con un divisor **constante**, igual en todos los nodos (2.7.4). En el ejemplo, con tres atributos binarios, $|Q| = 6$ y $\alpha^* = 0.05/6 \approx 0.0083$. Como $2 \cdot 10^{-9} < 0.0083$, la división se acepta.

Además hay dos reglas triviales: no se dividen nodos con 5 muestras o menos, y no se aceptan divisiones que produzcan un hijo con menos de 3 muestras. El crecimiento termina cuando ninguna hoja admite una división significativa, y las hojas son los grupos finales. El resultado es un algoritmo con **un solo parámetro** interpretable, el nivel α, que **no requiere fijar el número de grupos**.

51. 2.8.4 Limitaciones

Las tres que reconocen los autores:

1. Evaluar todas las divisiones candidatas en cada nodo es costoso.
2. No optimiza una función objetivo explícita, así que no hay garantía de que el árbol sea el mejor posible.
3. El estadístico χ^2 crece con el número de muestras y de atributos, lo que empuja los p-valores a cero y dificulta controlar los falsos descubrimientos con ese umbral (el problema de la 2.7.6).

Dos que se añaden desde la 2.7:

4. El p-valor de la división elegida se calcula *como si esa división se hubiera fijado de antemano*, sin tener en cuenta que se eligió por ser la de menor p-valor (el problema de la 2.7.5).
5. La suma de estadísticos supone independencia entre pruebas que *comparten la misma variable* Z, lo que no es cierto.

52. 2.8.5 Relación con la propuesta

La tabla compara componente por componente. Leída con lo visto en la 2.7, cada fila apunta a una herramienta:

Componente	SigTree	Propuesta	Herramienta (2.7)
Objeto que se divide	Muestras con atributos categóricos	Bloque de una matriz de conteos región × tiempo	(adaptación al problema)
División candidata	Presencia o ausencia de una categoría	Bipartición de las filas, de las columnas o de ambas	(adaptación)
Qué se prueba	Asociación entre la división y los demás atributos	Asociación entre la división y la *otra dimensión* del bloque	2.7.1
Estadístico	Suma de X^2	G^2 de la tabla colapsada, coherente con la I-divergencia	2.7.1 (G^2 se parte de forma exacta)
Distribución de referencia	χ^2 asintótica	*Bootstrap* de los días alrededor de la independencia del bloque, repitiendo la búsqueda	2.7.3 y 2.7.5
Comparaciones múltiples	Bonferroni uniforme	Reparto jerárquico del nivel a lo largo del árbol	2.7.4
Criterio de parada	Significancia y reglas triviales	Significancia, tamaño de efecto corregido por sesgo y reglas triviales	2.7.6

Las limitaciones de ambos métodos orientan el diseño. La elección heurística de K_R y K_T en ST-CC motiva que la resolución final no dependa solo de esos números, y la inflación del estadístico de SigTree con muestras grandes motiva complementar la significancia con un umbral de tamaño de efecto.

SigTree divide un árbol con pruebas de hipótesis y para cuando nada es significativo, sin fijar el número de grupos. La propuesta conserva ese principio y cambia cada pieza: G^2 en lugar de la suma de X^2, *bootstrap* de días en lugar de χ^2, reparto jerárquico del nivel en lugar de Bonferroni uniforme, y tamaño de efecto además de significancia.

Parte IX
Capítulo 3, bloque 1: visión general y formulación

53. Por qué existe el capítulo

El Capítulo 2 dejó un problema abierto. ST-CC resume cada bloque de su tablero con un solo valor, así que la interacción entre regiones y horarios que queda *dentro* de los bloques, el término (iii) de la descomposición de la sección 2.5, no se modela. Un patrón local, por ejemplo unas pocas regiones que se activan solo en la tarde, queda diluido en un bloque que parece uniforme. Para recuperarlo hacen falta dos cosas, una forma de subdividir un bloque sin tocar el resto de la matriz y un criterio estadístico para decidir si la subdivisión es real y cuándo parar. El Capítulo 2 aportó las herramientas (G^2, pruebas por simulación, control jerárquico, tamaño de efecto) y el Capítulo 3 las junta.

54. 3.1 Visión general

La idea cabe en una frase. Se refina mientras haya heterogeneidad local detectable y de tamaño relevante, y se para cuando todas las hojas sean indistinguibles de su modelo nulo. Es

el principio de SigTree llevado a una matriz. El método tiene cuatro etapas, que son construir la matriz O con sus D matrices diarias, obtener la partición base con BBAC$_I$ y la base C5, refinar cada bloque (dividir por filas, por columnas, de forma conjunta, o dejarlo como hoja) y resumir las hojas con su tamaño de efecto y su nivel de actividad.

La diferencia con subir K_R y K_T es que un corte global atraviesa toda la matriz y fragmenta también las zonas sin patrón, mientras que un corte de AST-CC afecta solo al bloque donde se detectó la heterogeneidad. Los parámetros crecen con la estructura local encontrada y no con la resolución global.

55. 3.2 Formulación

55.1. Notación y la cantidad central

Un bloque es $B = I \times J$, con I un subconjunto de regiones y J uno de horarios. Se calcula su tabla esperada bajo independencia, $E^B_{ij} = O^B_{i\cdot} O^B_{\cdot j}/N_B$, y su estadístico $G^2_B = 2\sum O_{ij} \log(O_{ij}/E^B_{ij})$, que es la sección 2.5 aplicada a un bloque. La información mutua empírica es $\hat{I}_B = G^2_B/(2N_B)$.

Ejemplo. Sea el bloque de cuatro regiones y dos horarios

	mañana	tarde
A	30	10
B	28	12
C	10	30
D	12	28

Cada fila suma 40 y cada columna 80, con $N_B = 160$, así que todos los esperados valen 20. Entonces $G^2_B = 2\sum O \ln(O/20) \approx 34.10$ con $(4-1)(2-1) = 3$ grados de libertad, y $\hat{I}_B = 34.10/320 \approx 0.107$ nats por viaje. Se ve que A y B se parecen, que C y D también, y que los dos pares son opuestos.

55.2. Corte, árbol y modelo local

Un corte parte un bloque de tres maneras, de filas (dos hijos), de columnas (dos hijos) o conjunto (cuatro hijos). El árbol de refinamiento tiene como hijos de la raíz los $K_R K_T$ bloques base, y debajo los cortes. Las hojas forman siempre una partición de la matriz con estructura de guillotina, porque cada corte actúa solo dentro de su bloque, y si no se corta nada coinciden con el tablero de ST-CC.

Cada hoja se aproxima con el modelo de independencia de su propio bloque, $\hat{O} = E^L$. La ventaja es que cada hoja tiene sus propios efectos de fila y de columna, así que las diferencias de volumen entre regiones no cuentan como patrón. El número de parámetros es $\sum_L (|I_L| + |J_L| - 1)$.

55.3. La proposición clave

Tiene tres partes. En (a), la divergencia del árbol es la mitad de la suma de las G^2 de sus hojas. En (b), si se corta B con s, entonces $G^2_B = G^2_{B,s} + \sum_C G^2_C$, un reparto exacto entre lo que explica el corte y lo que queda dentro de los hijos. En (c), cortar reduce la divergencia en exactamente $\frac{1}{2} G^2_{B,s}$, y $G^2_{B,s}$ es un estadístico de razón de verosimilitud con grados de libertad conocidos ($|J| - 1$ para filas, $|I| - 1$ para columnas, $|I| + |J| - 3$ para conjunto).

Ejemplo con el bloque anterior. Se cortan las filas en $\{A, B\}$ y $\{C, D\}$. La tabla colapsada es

	mañana	tarde
$\{A, B\}$	58	22
$\{C, D\}$	22	58

con esperados 40. Con la fórmula de la proposición, $\log \frac{O_{rj} N_B}{N_r O^B_{\cdot j}} = \log \frac{58 \cdot 160}{80 \cdot 80} = \ln 1.45$, y

$$G^2_{B,s} = 2 \cdot 2\,[58 \ln 1.45 + 22 \ln 0.55] \approx 33.59$$

con $|J| - 1 = 1$ grado de libertad. Cada hijo es casi homogéneo, por ejemplo $(30, 10;\ 28, 12)$ con esperados $(29, 11)$ y $G^2_C \approx 0.25$; los dos suman 0.51. Se comprueba el reparto, $33.59 + 0.51 \approx 34.10 = G^2_B$. El corte explica el 98.5 % de la heterogeneidad (33.59/34.10) con un solo parámetro más, pues antes hay $4 + 2 - 1 = 5$ parámetros y después $3 + 3 = 6$.

Por qué importan los grados de libertad. Un corte de columnas separa las dos columnas y explica el 100 %, pero con $|I| - 1 = 3$ grados de libertad. Con G^2 crudo parecería mejor, y por eso la comparación entre tipos de corte se hace con p-valores calibrados.

Lectura informacional. Dividiendo el reparto entre $2N_B$ se obtiene la regla de la cadena de la información mutua, así que la asociación del bloque se reparte sin pérdida ni duplicación entre lo que explica el corte y lo que queda en los hijos.

Por qué funciona (no va en la tesis). Dentro de cada hoja, la aproximación reproduce el total, así que los términos lineales de la I-divergencia se cancelan y queda $\sum O \log(O/E) = \frac{1}{2} G^2_L$. Para el reparto se usa la misma identidad pitagórica de la sección 2.5, aplicada a dos modelos anidados, el de independencia en B y el del corte. Su diferencia es la ganancia $G^2_{B,s}$, que resulta ser el G^2 de la tabla colapsada porque, tras un corte de filas, los totales de fila de cada hijo coinciden con los de B.

55.4. Relación con ST-CC (el corolario)

ST-CC deja sin modelar el término (iii), la suma de las G^2 de los bloques base. AST-CC lo reparte en una parte *explicada* (las ganancias de los cortes aceptados) y una parte *residual* (lo que queda en las hojas). Cada corte aceptado traslada $\frac{1}{2} G^2_{B,s}$ de la segunda a la primera. El reparto depende solo de la partición y no de la base con que se obtuvo, así que vale con C2 y con C5, y el criterio de refinamiento y el objetivo de ST-CC son la misma cantidad a distintas escalas.

55.5. Planteamiento del problema

El problema es minimizar la divergencia del árbol sujeto a que ninguna hoja tenga heterogeneidad significativa y relevante. No se resuelve de forma exacta porque el árbol se construye de forma voraz, de arriba abajo. La proposición garantiza que cada decisión local es coherente con el objetivo global, no que el árbol final sea óptimo. La versión penalizada tipo BIC, con $\lambda = \frac{1}{2} \log N$, no construye el árbol sino que sirve para comparar en una misma escala árboles de AST-CC con rejillas globales de distinto tamaño.

> Cortar un bloque reparte su G^2 de forma exacta entre lo que explica el corte y lo que queda en los hijos. Por eso cada corte se puede decidir con la información de su propio bloque sin perder coherencia con el objetivo global, y su ganancia es un estadístico de razón de verosimilitud al que se le puede aplicar una prueba de hipótesis.

Parte X
Capítulo 3, bloque 2: estadísticos y regla de decisión

56. Por qué existen estas secciones

La sección 3.2 mostró que cortar un bloque reparte su G^2 de forma exacta, pero no dijo cuándo conviene cortar ni dónde. La 3.3 define las preguntas estadísticas que se le hacen a cada bloque, y la 3.4 las junta en una regla que termina en una de tres decisiones, que son cortar, dejar el bloque como hoja homogénea o dejarlo como hoja heterogénea no localizada.

57. 3.3 Estadísticos de heterogeneidad

57.1. 3.3.1 Elección del modelo nulo

Hay dos candidatos para lo que se considera comportamiento esperado dentro de un bloque. La *constancia* supone que todas las celdas valen lo mismo, $\mu_{ij} = \theta$, y es el nulo implícito en la base C2. La *independencia* supone $\mu_{ij} = a_i b_j$, un efecto de región multiplicado por un efecto de horario.

Ejemplo. Sea el bloque con filas $(80, 20)$ y $(40, 10)$, con $N = 150$. La segunda región tiene la mitad del volumen de la primera pero el mismo perfil, pues ambas ponen el 80 % en la mañana. No hay ningún patrón local.

- Bajo constancia el esperado es 37.5 en todas las celdas y $G^2 = 2\,[80 \ln \frac{80}{37.5} + 20 \ln \frac{20}{37.5} + 40 \ln \frac{40}{37.5} + 10 \ln \frac{10}{37.5}] \approx 74.8$ con 3 grados de libertad, que se rechaza con claridad.
- Bajo independencia los esperados son exactamente $(80, 20)$ y $(40, 10)$, así que $G^2 = 0$.

Con datos de movilidad, donde las zonas tienen volúmenes muy distintos, la constancia rechazaría casi todos los bloques solo por el volumen, que son los términos (i) y (ii) de la descomposición. La independencia aísla el término (iii), y rechazarla significa que algunas regiones se activan en algunos horarios de forma distinta al resto, que es la definición operativa de patrón local de esta tesis.

57.2. 3.3.2 Prueba ómnibus

La primera pregunta es si el bloque contiene algo que refinar, y se responde con G^2_B. Con conteos de Poisson independientes bastaría una simulación condicionada a los totales, pero los taxis tienen una varianza entre días mucho mayor que la media. Con var/media ≈ 3, el valor típico de G^2_B bajo el nulo ronda 3ν en lugar de ν. Con $\nu = 12$ serían unas 36 unidades en lugar de 12, y una prueba χ^2 con 12 grados de libertad daría $p < 0.001$ en un bloque que no tiene nada. Por eso el nulo se genera remuestreando los días reales (sección 3.5).

57.3. 3.3.3 Pruebas dirigidas

Si el ómnibus rechaza, la segunda pregunta es qué corte captura la estructura. Para cada tipo se toma el máximo de la ganancia $G^2_{B,s}$ sobre los candidatos. Dentro de un tipo todos los candidatos tienen los mismos grados de libertad, así que el de mayor G^2 es el de menor p-valor, igual que SigTree elige la división de menor p-valor.

La observación del nulo común. El bloque es independiente si y solo si todas sus filas tienen el mismo perfil sobre las columnas, de modo que el ómnibus y las dirigidas contrastan la misma hipótesis con estadísticos de distinta potencia. Las dirigidas solo se hacen si el ómnibus rechazó, así que para que un bloque nulo se refine hay que rechazar primero el ómnibus, lo que ocurre con probabilidad a lo sumo α_B. Las dirigidas localizan la estructura y no añaden oportunidades de falso rechazo.

Un caso que parece problemático. Sean las filas $(30, 10)$, $(10, 30)$, $(30, 10)$ y $(10, 30)$. Todos los totales de fila valen 40 y los de columna 80, así que las marginales no muestran nada. Sin embargo el corte $\{1, 3\}$ frente a $\{2, 4\}$ colapsa el bloque en $(60, 20)$ y $(20, 60)$, con esperados 40, y

$$G^2_{B,s} = 2 \cdot 2\,[60 \ln 1.5 + 20 \ln 0.5] \approx 41.9.$$

El corte compara los perfiles completos de los grupos y no sus totales. Por eso los cortes unidimensionales bastan para la mayoría de las estructuras, y el conjunto se reserva para cuando la evidencia está repartida entre ambas dimensiones.

57.4. 3.3.4 Generación de cortes candidatos

Un bloque con $|I|$ filas admite $2^{|I|-1} - 1$ biparticiones. Con 4 filas son 7, con 14 son 8191 y con 15 serían 16383, así que cada fila adicional duplica el número de candidatos.

Columnas. Con $n = 12$ hay a lo sumo $2^{11} - 1 = 2047$ biparticiones, y se enumeran todas.

Filas. Si $|I| \leq 14$ se enumeran. Por encima se usa un 2-medias con divergencia KL ponderada. Maximizar la ganancia de un corte de filas equivale a minimizar $\sum_i O^B_{i\cdot} \mathrm{KL}(p(\cdot|i) \,\|\, p(\cdot|r(i)))$, donde $p(\cdot|i)$ es el perfil horario de la fila i. Es un K-means de dos grupos que agrupa las filas por la forma de su perfil y no por su volumen, y es el paso de filas del co-agrupamiento de Dhillon con dos grupos. Cada fila va al grupo cuyo perfil promedio se parece más al suyo, y se repite hasta que nadie cambia, desde $R_{\text{ini}} = 10$ inicios aleatorios.

Conjunto. La ganancia de un corte conjunto equivale a minimizar la suma de las G^2 de los cuatro hijos. Si $|J| \leq 6$ y $|I| \leq 14$ se recorren todos los cortes de columnas y, para cada uno, se elige el mejor de filas, lo que da el óptimo exacto. En bloques mayores se alternan ambos pasos.

Una búsqueda heurística no invalida la prueba. Siempre que el mismo procedimiento se repita en cada réplica nula, el p-valor es válido para el estadístico que efectivamente se calcula, aunque no sea el máximo exacto. Lo que se pierde es potencia, y por eso se prefiere enumerar siempre que se pueda.

58. Por qué el límite es 14 filas

El 14 no es un número teórico sino un compromiso entre exactitud y costo, y conviene tener claras sus tres piezas.

1. Por qué enumerar. El 2-medias es una heurística que puede quedarse en un mínimo local. En una comprobación sobre 40 tablas de 8×5, en las que el óptimo se calcula enumerando, lo alcanzó en alrededor del 92 % de los casos con diez inicios, y nunca lo superó, porque una heurística no puede ganarle al óptimo. Ese 8 % de fallos es lo que justifica enumerar siempre que se pueda. Importa porque el p-valor compara el máximo observado con el máximo bajo el nulo, y un máximo mal encontrado resta potencia.

2. Por qué no enumerar siempre. Cada fila adicional duplica los candidatos, y la búsqueda no se hace una vez sino en cada réplica nula. Con $|I| = 14$ son 8191 candidatos, cada uno una tabla colapsada $2 \times |J|$. Con las B_{perm} réplicas, que van de 199 a 20 000 según el nivel del bloque, y las tres búsquedas (filas, columnas y conjunta), el trabajo ya es considerable. Con 15 filas se duplicaría, y con 20 filas serían más de medio millón de candidatos por réplica. Además la implementación procesa las réplicas por lotes en memoria, y el lote que cabe se reduce a la mitad por cada fila adicional.

3. Por qué 14 y no 13 o 15. El valor concreto es una elección práctica, no un umbral que salga de una fórmula. Es el tamaño hasta el cual la enumeración sigue siendo manejable con el número de réplicas de referencia. Lo que sí se comprobó es que, con este límite, todos los bloques base de los datos de esta tesis, que tienen a lo sumo quince filas, se resuelven de forma casi siempre exacta, pues solo los de quince filas, si los hay, usan la heurística.

Advertencia honesta. El 92 % se midió con tablas de ocho filas, no de quince. Con más filas el 2-medias podría fallar algo más, y eso es lo que justifica no extender la heurística a bloques grandes. Si el jurado pregunta, la respuesta es que 14 es un compromiso de costo, que el fallo de la heurística se midió en tablas pequeñas, y que la validez de la prueba no depende de que la búsqueda sea exacta, solo de que se repita igual en las réplicas.

59. 3.4 Regla de decisión

La regla combina el ómnibus, las dirigidas y el umbral de tamaño de efecto δ, con α_B el nivel asignado al bloque.

1. **Puerta ómnibus.** Si $p_{\text{omn}} > \alpha_B$ o $\tilde{I}_B < \delta$, el bloque es una hoja homogénea.
2. **Cortes unidimensionales.** Si solo uno de p_{fil}, p_{col} es $\leq \alpha_B$, se aplica el mejor corte de esa dimensión. Si lo son los dos, se aplica el de menor p-valor y la recursión decide sobre la otra. Los empates se resuelven con $z = (G^2 - \nu)/\sqrt{2\nu}$.
3. **Corte conjunto.** Si ninguno es significativo pero el ómnibus sí lo fue, se evalúa el 2×2. Si $p_{\text{conj}} \leq \alpha_B$ se aplica, y si no, el bloque es una hoja heterogénea no localizada.
4. **Ganancia mínima.** El corte elegido solo se acepta si $\tilde{g}_{B,s} \geq \delta$. Si no, el bloque también queda como hoja heterogénea no localizada.

Cuatro trayectorias con números. Sea $\alpha_B = 0.01$ y $\delta = 0.005$.

- **A.** $p_{\text{omn}} = 0.2$. El ómnibus no rechaza y el bloque es hoja homogénea.
- **B.** $p_{\text{omn}} = 0.002$, $\tilde{I}_B = 0.03 \geq \delta$, $p_{\text{fil}} = 0.004$ y $p_{\text{col}} = 0.3$. Solo el corte de filas es significativo, se aplica, y si $\tilde{g} \geq \delta$ se recurre en cada hijo.
- **C.** Ambos p-valores valen 0.001, el mínimo con 999 réplicas. El corte de filas tiene $G^2 = 60$ con $\nu = 5$ y el de columnas $G^2 = 45$ con $\nu = 9$. Entonces $z_{\text{fil}} = 55/\sqrt{10} \approx 17.4$ y $z_{\text{col}} = 36/\sqrt{18} \approx 8.5$, y gana el corte de filas.
- **D.** El ómnibus rechaza pero ni los cortes unidimensionales ni el conjunto son significativos. El bloque queda como hoja heterogénea no localizada.

Las tres decisiones de diseño.

- *Un corte por nivel.* Cortar ambas dimensiones a la vez pasaría de uno a cuatro bloques cuando quizá bastan dos. Cortar una por nivel añade menos parámetros y da una lectura direccional, pues si el bloque se divide por filas la heterogeneidad es espacial, y si se divide por columnas, temporal.
- *El corte conjunto como recurso.* Su modelo contiene a los de filas y de columnas, así que su estadístico es al menos tan grande como cualquiera de ellos y puede alcanzar significancia cuando la estructura está repartida entre ambas dimensiones.
- *Dos tipos de hoja.* La homogénea no muestra interacción. La heterogénea no localizada sí la muestra, pero ningún corte simple la captura. Reportarlas por separado evita presentar como homogéneo un bloque que no lo es.

La regla es una cascada de puertas. Primero se pregunta si hay algo (ómnibus y tamaño de efecto), luego dónde (filas, columnas, conjunto) y por último si vale la pena (ganancia mínima). El error de tipo I lo controla la primera puerta, y las demás solo localizan. El límite de 14 filas es un compromiso entre exactitud de la búsqueda y costo, y no afecta la validez de la prueba.

Parte XI
Capítulo 3, bloque 3: calibración de las pruebas

60. Por qué existe esta sección

Todas las pruebas de la 3.3 y la 3.4 terminan pidiendo un p-valor, y un p-valor solo vale si se sabe cómo se comporta el estadístico cuando no hay patrón. Con conteos de Poisson independientes esa distribución se conoce, pero los datos de taxis no lo son. La sección responde a una pregunta práctica, que es cómo fabricar tablas nulas que se parezcan a los datos reales salvo por la ausencia de interacción. Tiene tres partes: medir qué tan lejos está Poisson de la realidad, construir la nula con *bootstrap* de días y corregir que el corte probado fue elegido como el mejor.

61. 3.5.1 Variabilidad entre días

La matriz es la suma de D días, así que cada celda tiene réplicas diarias X_{dij} y se puede contrastar Poisson directamente. Con Poisson, var/media valdría 1 en todas las celdas.

	Laborable ($D = 12$)	Feriado ($D = 9$)
Mediana de var/media	3.2	17.1
Con media diaria en $[5, 50)$	2.0	2.8
Con media diaria ≥ 500	4.3	49.1
Exponente b de var $= a\mu^b$	1.22	1.81
Dispersión de Pearson tras quitar efectos día–región y día–intervalo	2.1	6.7

Hecho 1: la sobredispersión es sustancial. Una celda típica tiene varianza 3 veces su media en día laborable y 17 veces en feriado. Con la nula de Poisson, la prueba rechazaría la independencia solo por esto.

Hecho 2: no es constante y crece con el volumen. Un modelo cuasi-Poisson usa un único factor φ. Con $\varphi = 17.1$, la mediana del feriado, una celda poco activa con razón 2.8 se corrige de más unas 6 veces (17.1/2.8), y una muy activa con razón 49.1 se corrige de menos casi 3 veces (49.1/17.1). Las muy activas son las que concentran la masa del bloque.

Hecho 3: una parte no afecta a la prueba y otra es correlacionada. Si un día multiplica la intensidad de toda una región por un factor, la suma sobre los días sigue siendo un producto de efecto de fila por efecto de columna.

Ejemplo. Sea $a = (1, 2)$ para dos regiones y $b = (10, 20)$ para dos horarios. El día 1 tiene $\gamma = (1, 1)$ y el día 2 tiene $\gamma = (2, 0.5)$, es decir, en el día 2 la región 1 está muy activa y la 2 poco. Sumando los dos días, la región 1 queda con $1 \cdot (1 + 2) \cdot (10, 20) = (30, 60)$ y la región 2 con $2 \cdot (1 + 0.5) \cdot (10, 20) = (30, 60)$. Las filas son proporcionales, así que el bloque sigue siendo independiente y no hay patrón falso.

Lo que sí queda es la combinación de efectos día–región y día–intervalo, que produce desviaciones correlacionadas entre las celdas de un bloque con forma de interacción, y cuyo peso en G^2 crece con la masa del bloque. Una nula que trate cada celda por separado no puede reproducirlas, y por eso se remuestrean días completos.

62. 3.5.2 *Bootstrap* de días

El p-valor. Se generan B réplicas nulas y se cuenta cuántas tienen un estadístico mayor o igual al observado, $p = (1 + \#)/(1 + B)$. Con $B = 199$ y 4 réplicas por encima, $p = 5/200 = 0.025$. Si ninguna supera, $p = 1/200 = 0.005$. Nunca vale 0, y el mínimo posible es $1/(B + 1)$.

La réplica. Para cada celda con media diaria $\bar{X} \geq 0.5$ se calcula la fluctuación de cada día, $F_d = X_d/\bar{X}$, y luego se corrige, $\tilde{F} = \text{máx}\{0,\ 1 + \sqrt{D/(D-1)}\,(F - 1)\}$. La corrección compensa que la varianza empírica de D días subestima la poblacional.

Ejemplo. Una celda con $D = 4$ días y conteos $(80, 100, 90, 130)$, con media 100. Las fluctuaciones son $F = (0.8, 1.0, 0.9, 1.3)$. El factor es $\sqrt{4/3} = 1.1547$ y las corregidas quedan $\tilde{F} = (0.769,\ 1.0,\ 0.885,\ 1.346)$. Las desviaciones al cuadrado suman 0.14, que dividido entre D da 0.035 y dividido entre $D - 1$ da 0.0467. La corrección multiplica la varianza por 4/3 y la deja insesgada.

Una réplica. Se sortean 4 días con reemplazo, por ejemplo los días $(4, 1, 4, 2)$. La suma de sus $\tilde{F}$ es $1.346 + 0.769 + 1.346 + 1.0 = 4.461$. Si la esperada de independencia del bloque es $E^B = 400$, la réplica vale $400/4 \cdot 4.461 = 446.1$, y se redondea de forma estocástica a 446 o 447 sin sesgo.

Por qué es una nula válida. La media de $\tilde{F}$ sobre los días es exactamente 1, así que la media de las réplicas es E^B y se cumple el nulo. Si un día solo difiere por un factor común a una región o a un intervalo, su fluctuación es de rango uno y la réplica sigue siendo independiente. La combinación de efectos y la variación propia de cada celda se trasladan tal como aparecen en los datos. El método no supone ninguna forma para la varianza ni para la correlación, pero sí que los días son independientes y que E^B estima bien las medias.

Evidencia de calibración. Para cada bloque base, 300 réplicas generadas con la fórmula anterior cumplen la independencia por construcción y conservan la variabilidad real. Error de tipo I al nivel 0.05, como media sobre los 24 bloques.

Nula	Laborable	Feriado
Poisson	0.40	0.76
Cuasi-Poisson	0.03	0.01
Gamma–Poisson	0.02	0.06
Bootstrap sin corrección	0.06	0.11
Bootstrap con corrección	**0.04**	**0.09**

Poisson rechaza una independencia verdadera en el 40 % y el 76 % de los casos. Las nulas por celda son conservadoras en la mayoría de los bloques y liberales en los de mayor volumen. El *bootstrap* corregido es el único centrado en el nominal en el periodo laborable.

El feriado. El generador mezcla al azar sábados, domingos y el Día de Acción de Gracias, mientras la matriz real tiene siempre la misma composición. Con un generador que la respeta, el error medio baja a 0.045, aunque 5 de los 24 bloques, casi todos nocturnos, siguen por encima, con máximo 0.30. Remuestrear dentro de cada tipo de día empeora a 0.11, porque con solo cuatro sábados y cuatro domingos no hay datos suficientes. Por eso se usa el *bootstrap* sin estratos y la liberalidad residual se declara como limitación. Como estos datos nulos comparten mecanismo con el *bootstrap*, lo que podría favorecerlo, la calibración final se medirá también con datos sintéticos de otro mecanismo.

63. 3.5.3 Corrección por la búsqueda del mejor corte

El corte que se prueba se eligió porque maximiza la separación. Si su G^2 se comparara con una χ^2 de un corte fijado de antemano, el p-valor estaría sesgado hacia cero.

Intuición. Con 7 cortes candidatos independientes de 1 grado de libertad, la probabilidad de que al menos uno supere el umbral del 5 % de una χ^2 es $1 - 0.95^7 \approx \mathbf{0.30}$ y no 0.05. Los candidatos reales están correlacionados, así que es menos, pero el sesgo sigue ahí, y con las 2047 biparticiones de columnas es mucho mayor. Es el doble uso de los datos que documentan Gao y colaboradores en el agrupamiento jerárquico.

La corrección tipo *min-P*. En cada réplica nula se repite la búsqueda completa del mejor corte y se registra su máximo. El p-valor compara el máximo observado con la distribución del máximo bajo el nulo. Ajusta a la vez por el número de candidatos y por su correlación, con más potencia que Bonferroni. En la comprobación preliminar, comparar el mejor corte con una χ^2 fija dio errores de tipo I de hasta 0.98 al nivel 0.05, y con *min-P* el error medio fue 0.050. Las pruebas dirigidas reutilizan las mismas réplicas del ómnibus, así que el costo de generarlas se paga una sola vez por bloque.

64. 3.5.4 Alcance de la corrección

La repetición de la búsqueda corrige la selección del corte dentro de un nodo, pero no la selección del propio nodo. Los bloques base vienen de BBAC_I, que arma los grupos de modo que sean lo más distintos posible entre sí, y los hijos vienen de cortes elegidos por separar bien los mismos datos con que luego se prueban. Aunque cada prueba individual esté bien calibrada, el error del método completo puede ser mayor que el nominal, y por eso el capítulo de resultados incluye un experimento sobre datos nulos que mide cuántos refinamientos espurios produce el método completo.

El p-valor solo es honesto si la nula se parece a los datos reales. Remuestrear días completos conserva la correlación entre celdas que Poisson y las nulas por celda pierden, y repetir la búsqueda del mejor corte en cada réplica evita el sesgo de haberlo elegido con los mismos datos. Lo que queda sin corregir es la selección de los propios nodos, y eso solo lo mide el experimento con datos nulos.

Parte XII
Capítulo 3, bloque 4: comparaciones múltiples y criterios de parada

65. Por qué existen estas secciones

Un árbol de refinamiento no hace una prueba sino muchas, una por cada bloque base y, en cascada, una por cada hijo. Si todas usan $\alpha = 0.05$, la probabilidad de algún falso refinamiento crece rápido. La sección 3.6 reparte el nivel de significancia para que el árbol completo tenga un error global controlado. La 3.7 resuelve otro problema, que es que con millones de viajes casi cualquier desviación resulta significativa, y por eso se exige además un tamaño de efecto mínimo y se fijan reglas para detenerse.

66. 3.6 Control de comparaciones múltiples

El problema. Con 20 pruebas independientes al 5 %, la probabilidad de al menos un falso rechazo es $1 - 0.95^{20} \approx 64$ %. SigTree divide α entre el número de pruebas (Bonferroni), pero ignora la estructura jerárquica y resulta demasiado conservador.

El reparto por masa. El nivel global se reparte de arriba abajo en proporción a la masa de cada bloque. Para los bloques base, $\alpha_B = \alpha N_B/N$, y para los hijos, $\alpha_C = \alpha_B N_C/N_B$.

Ejemplo. Sea $N = 10\,000$ viajes y $\alpha = 0.05$, con cuatro bloques base de 4000, 3000, 2000 y 1000 viajes. Sus niveles son 0.020, 0.015, 0.010 y 0.005, que suman 0.05. Si el bloque de 4000 se corta en hijos de 3000 y 1000, estos reciben $0.02 \cdot 0.75 = 0.015$ y $0.02 \cdot 0.25 = 0.005$, que suman lo que tenía el padre. Con Bonferroni sobre 20 pruebas todos recibirían 0.0025, y el bloque de 4000 trabaja con 0.02, ocho veces más, lo cual es razonable porque tiene más datos y más potencia. Además, un bloque solo se prueba si su padre fue refinado, y los niveles de los bloques que nunca se visitan no se gastan.

El argumento de control. Si el nulo de independencia se cumple en un bloque, se cumple en todos sus sub-bloques, así que los nulos verdaderos forman subárboles completos. Un falso rechazo ocurre por primera vez en la raíz de alguno de esos subárboles, y esas raíces son bloques disjuntos cuyos niveles suman a lo sumo α. En el ejemplo, si los bloques de 2000 y 1000 viajes fueran verdaderamente nulos, la probabilidad de refinarlos por error sería a lo sumo $0.010 + 0.005 = 0.015 \leq 0.05$. Eso da control de la tasa de error por familia (FWER), la probabilidad de al menos un falso refinamiento en todo el árbol. La salvedad honesta es que la jerarquía se construye con los datos, así que la garantía es aproximada, y su comportamiento real lo mide el experimento de calibración del capítulo de resultados.

Consecuencia práctica, el número de réplicas. El nivel de un bloque pequeño puede ser menor que la resolución del p-valor por simulación, $1/(B+1)$. Por eso $B_{\text{perm}} = \text{máx}\{B_{\text{mín}}, \lceil c/\alpha_B \rceil\}$, acotado por $B_{\text{máx}}$, con $B_{\text{mín}} = 199$, $c = 2$ y $B_{\text{máx}} = 20\,000$.

α_B	$\lceil 2/\alpha_B \rceil$	B_{perm}	Resultado
0.02	100	199	Se usa el mínimo
0.005	400	400	Se adapta
0.0001	20 000	20 000	Llega al máximo
0.00002	100 000	20 000	$p_{\text{mín}} = 5 \cdot 10^{-5} > \alpha_B$, hoja inalcanzable

Una hoja inalcanzable no es una hoja homogénea. El método no afirma que el bloque sea homogéneo, sino que no puede probarlo al nivel asignado.

Parada secuencial de Besag y Clifford. La simulación se detiene en cuanto se acumulan $h = 10$ réplicas con estadístico mayor o igual al observado. Si el bloque claramente no es significativo, por ejemplo con $p \approx 0.5$, eso ocurre tras unas 20 réplicas en lugar de 199. Los bloques que sí pasan el ómnibus completan la simulación, y esas réplicas sirven para las pruebas dirigidas.

67. 3.7 Criterios de parada

Significancia frente a tamaño de efecto. Un bloque con $N = 10^6$ viajes e $\hat{I} = 0.0005$ tiene $G^2 = 2 \cdot 10^6 \cdot 0.0005 = 1000$, un p-valor prácticamente nulo y una interacción irrelevante. Con $\delta = 0.005$ es hoja. Otro con $N = 1000$ e $\hat{I} = 0.05$ tiene $G^2 = 100$, y si pasa la prueba también supera δ, así que se refina. La significancia crece con N y el tamaño de efecto no.

Los siete criterios.

Criterio	Condición para ser hoja	Cuándo importa
Tamaño mínimo	$\|I\| < 2$ o $\|J\| < 2$	Con una sola fila o columna, $G^2 = 0$
Masa mínima	$N_B < N_{\text{mín}}$ (500)	Bloques con muy poca actividad
Profundidad máxima	$d \geq d_{\text{máx}}$ (6)	Acota costo y complejidad
Nivel inalcanzable	$1/(B_{\text{máx}} + 1) > \alpha_B$	La prueba no podría rechazar
Significancia	$p_{\text{omn}} > \alpha_B$ o ningún corte $\leq \alpha_B$	No hay evidencia o no se localiza
Tamaño de efecto	$\tilde{I}_B < \delta$	Interacción irrelevante
Ganancia del corte	$\tilde{g} < \delta$	El corte explica muy poco

Los cuatro primeros son reglas triviales, análogas a las de SigTree, que no dependen de la estructura interna del bloque. Los tres últimos son estadísticos.

El umbral δ. Es la defensa principal contra la inflación por tamaño de muestra y tiene una interpretación directa, información mutua en nats por observación, sin crecer con N. En los bloques base de ST-CC el cociente G^2/ν va de 3 a más de 1700 y la prueba de independencia rechaza en casi todos. Por eso, en los primeros niveles del árbol decide δ, y la prueba cobra importancia en los bloques pequeños y profundos, donde la masa es menor.

Tamaño de efecto corregido por sesgo. Aun sin interacción, $\mathrm{E}[G^2] \approx \nu$, así que $\mathrm{E}[\hat{I}] \approx \nu/(2N) > 0$. Un bloque de 1033 viajes con $\nu = 12$ tiene $\hat{I} = 0.017$, y cerca de un tercio, $12/2066 \approx 0.006$, es ruido de Poisson. La versión corregida es $\tilde{I} = \max\{0, (G^2 - \bar{t}_0)/(2N)\}$, con $\bar{t}_0$ la media de G^2 bajo las réplicas nulas.

Ejemplo ilustrativo. Aquí $G^2 = 2 \cdot 1033 \cdot 0.017 \approx 35.1$. Restando el $\nu = 12$ de Poisson, $\tilde{I} = (35.1 - 12)/2066 \approx 0.011$. Con sobredispersión de 2.1, como en el periodo laborable, $\bar{t}_0$ sería más cercano a 25 y entonces $\tilde{I} = (35.1 - 25)/2066 \approx 0.005$. Los 25 son una cifra supuesta solo para mostrar el efecto. El mismo bloque pasa de 0.017 a 0.011 y a 0.005 según cuánto ruido se descuente. La ganancia corregida $\tilde{g}$ funciona igual, pero con $\bar{t}_{0,s}$ calculado repitiendo la búsqueda,

así que descuenta además el optimismo de haber elegido el mejor corte. Ambas medias salen de las réplicas que ya se generaron para los p-valores, sin costo adicional.

Elección de δ. No se fija a priori. Los $\hat{I}$ de los bloques base van de 0.0012 a 0.061 en laborable y de 0.0017 a 0.19 en feriado. En el capítulo de resultados se recorre una rejilla como $\{0.001, 0.0025, 0.005, 0.01, 0.02\}$, y para cada valor se reportan el número de hojas, la fracción del término de interacción local que explica el árbol y la estabilidad de las hojas. Como medida estandarizada complementaria puede reportarse la V de Cramér.

El nivel α se reparte por masa a lo largo del árbol, de modo que los bloques con más datos tienen más poder de rechazo y el error global queda acotado. Con muchos datos casi todo es significativo, por eso la significancia se acompaña de un umbral de tamaño de efecto δ, corregido por el sesgo que produce el ruido, y de reglas triviales de parada.

Parte XIII
Capítulo 3, bloque 5: el algoritmo

68. Por qué existe esta sección

Hasta ahora el método se presentó por piezas, que son el reparto de G^2, la prueba ómnibus, las pruebas dirigidas, la nula con *bootstrap*, el reparto del nivel y los criterios de parada. La sección 3.8 las junta en dos pseudocódigos que se pueden implementar, fija los valores de referencia de los parámetros y estima el costo, para mostrar que el método es ejecutable en datos reales.

69. 3.8 Algoritmo

69.1. Algoritmo 1: Refinar

La entrada es la matriz O con sus D días y los parámetros. Primero se obtiene la partición base con BBAC_I y luego se llama a Refinar sobre cada bloque base con nivel $\alpha N_B/N$ y profundidad 0. Refinar sigue seis pasos.

1. **Reglas triviales.** Si $|I| < 2$, $|J| < 2$, $N_B < N_{\text{mín}}$ o $d \geq d_{\text{máx}}$, el bloque es hoja.
2. **Número de réplicas.** Se calcula B_{perm}. Si $1/(B_{\text{perm}} + 1) > \alpha_B$, es hoja inalcanzable.
3. **Puerta ómnibus.** Se calcula G^2_B, se generan las réplicas por *bootstrap* de días (con parada de Besag y Clifford) y se obtienen p_{omn}, $\bar{t}_0$ y $\tilde{I}_B$. Si $p_{\text{omn}} > \alpha_B$ o $\tilde{I}_B < \delta$, es hoja homogénea.
4. **Pruebas dirigidas.** Se llama a MejorCorte para filas y para columnas con las mismas réplicas. Si el menor p-valor es $\leq \alpha_B$, se elige ese corte (desempate por z). Si no, se prueba el conjunto, y si tampoco es significativo, es hoja heterogénea no localizada.
5. **Ganancia mínima.** Se calcula $\tilde{g}$. Si $\tilde{g} < \delta$, es hoja heterogénea no localizada.
6. **Recursión.** Se llama a Refinar sobre cada hijo con $\alpha_C = \alpha_B N_C/N_B$ y profundidad $d+1$.

Seguimiento con números. Sea $N = 10\,000$, $\alpha = 0.05$ y un bloque base de 4000 viajes con $\alpha_B = 0.02$ y $\delta = 0.005$.

- Pasa las reglas triviales, pues tiene filas y columnas de sobra, $4000 \geq 500$ y $d = 0$.

- $B_{\text{perm}} = \text{mín}\{20\,000, \text{máx}\{199, \lceil 2/0.02 \rceil = 100\}\} = 199$. El p mínimo es $1/200 = 0.005 \leq 0.02$, así que es alcanzable.
- Supón $p_{\text{omn}} = 0.005$ y $\tilde{I} = 0.03 \geq \delta$. Pasa la puerta.
- Supón $p_{\text{fil}} = 0.005$ y $p_{\text{col}} = 0.4$. Solo el corte de filas es significativo y se elige.
- Supón $\tilde{g} \geq \delta$. Se acepta y se recurre en cada hijo. Si el corte dejó hijos de 3000 y 1000 viajes, reciben 0.015 y 0.005. El hijo de nivel 0.005 usa $B_{\text{perm}} = \text{máx}\{199, 400\} = 400$ y repite todo el proceso.

La recursión termina cuando todas las ramas llegan a una hoja, y el resultado es el árbol con cada hoja etiquetada como homogénea, heterogénea no localizada o inalcanzable.

Una precisión sobre las réplicas. La parada secuencial se activa solo cuando se acumulan $h = 10$ réplicas por encima del observado, lo que implica un p-valor mayor que α_B (con $B_{\text{perm}} \approx 2/\alpha_B$, esas 10 réplicas equivalen a un p-valor de al menos $5\alpha_B$). Por eso, si el bloque pasa la puerta ómnibus, la simulación ya estaba completa y MejorCorte puede reutilizarla sin pasos adicionales.

69.2. Algoritmo 2: MejorCorte con *min-P*

Recibe un bloque, un tipo de corte y las réplicas nulas, y hace cuatro cosas.

1. Busca el mejor corte en el bloque observado y calcula $t_{\text{obs}} = G^2_{B,s^*}$.
2. **Repite la búsqueda completa en cada réplica**, y no solo evalúa el corte encontrado en los datos reales. Esa repetición es lo que corrige el sesgo de haber elegido el mejor corte.
3. Calcula $p = (1 + \#\{t_b \geq t_{\text{obs}}\})/(1 + B_{\text{perm}})$.
4. Devuelve el corte, el p-valor y la media $\bar{t}$ de los t_b, que alimenta la corrección por sesgo de $\tilde{g}$.

69.3. La tabla de parámetros

Los parámetros son de dos tipos. Las *decisiones del investigador*, que se someten a análisis de sensibilidad, son K_R y K_T (resolución inicial, tomados de Liu), $\alpha = 0.05$, δ (rejilla en $[0.001, 0.02]$ nats), $N_{\text{mín}} = 500$ y $d_{\text{máx}} = 6$. Los *parámetros técnicos*, que dan fiabilidad a la prueba sin ser el foco de la interpretación, son las 200 inicializaciones de BBAC_I, $B_{\text{mín}} = 199$, $c = 2$, $B_{\text{máx}} = 20\,000$, $h = 10$, los límites de enumeración $|I| \leq 14$ y $|J| \leq 6$, y $R_{\text{ini}} = 10$ del 2-medias. Todos estos valores coinciden con los de la implementación (`astcc/arbol.py`).

Una nota de consistencia. El criterio de nivel inalcanzable de la tabla de parada usa $B_{\text{máx}}$ y el algoritmo usa B_{perm}, que está acotado por $B_{\text{máx}}$. Son equivalentes, porque si α_B es grande la prueba es alcanzable con B_{perm} y si es pequeño B_{perm} llega a $B_{\text{máx}}$.

69.4. Costo computacional

Partición base. Cuesta lo mismo que ST-CC, $O(mn(K_R + K_T))$ por iteración. La búsqueda local evalúa cada movimiento en $O(K_R K_T)$, porque con las bases C2 y C5 la divergencia solo depende de los totales de bloque.

Refinamiento. El costo extra está en las pruebas por simulación. Por bloque, el orden es

$$B_{\text{perm}}\left[\,2^{|J|}|I| + 2^{\min(|I|,14)}|J|\,\right],$$

donde el primer término es la búsqueda de columnas y el segundo la de filas. Con $n = 12$ y bloques base de a lo sumo 15 filas, quedan acotados.

Bloque	Términos por réplica	Con 199 réplicas	Con 20 000
$\lvert I\rvert = 10$, $\lvert J\rvert = 12$	$2^{12} \cdot 10 + 2^{10} \cdot 12 \approx 5 \cdot 10^4$	$\approx 10^7$	$\approx 10^9$
$\lvert I\rvert = 14$, $\lvert J\rvert = 12$	$2^{12} \cdot 14 + 2^{14} \cdot 12 \approx 2.5 \cdot 10^5$	$\approx 5 \cdot 10^7$	$\approx 5 \cdot 10^9$

Son órdenes de magnitud de operaciones elementales, no tiempos medidos. Los bloques con 20 000 réplicas son los de nivel muy pequeño y poca masa, que se vuelven hojas pronto.

Tres propiedades mantienen el costo manejable. La parada secuencial abandona pronto los bloques no significativos. Los bloques de un mismo nivel son independientes dado el árbol, por lo que se procesan en paralelo. Y el tamaño de los bloques decrece con la profundidad.

El algoritmo es una recursión que, en cada bloque, hace tres preguntas en orden (si hay algo, dónde y si vale la pena), reutiliza las mismas réplicas nulas para todas ellas y reparte el nivel α a los hijos en proporción a su masa. El costo extra frente a ST-CC está solo en las simulaciones, y la parada secuencial, el paralelismo por niveles y la reducción de tamaño lo mantienen manejable.

Parte XIV
Capítulo 3, bloque 6: representación de los resultados

70. Por qué existe esta sección

ST-CC se lee fácil porque la partición es un tablero, con K_T patrones espaciales con su dinámica temporal y K_R patrones temporales con su distribución espacial. Con refinamiento local esa lectura deja de existir como un solo objeto, porque la partición temporal puede cambiar de un subconjunto de regiones a otro. Si el método devolviera solo un árbol de hojas sería correcto pero difícil de interpretar. La sección define cinco productos que devuelven la interpretabilidad que se pierde al abandonar la rejilla.

71. 3.9 Los cinco productos

71.1. 1. Descriptores de hoja

Para cada hoja se reportan sus regiones y horarios, su masa N_L, su interacción residual corregida $\tilde{I}_L$, su tipo (homogénea, heterogénea no localizada o inalcanzable) y su nivel de actividad relativo

$$\ell_L = \frac{N_L}{\sum_{(i,j)\in L} O_{i\cdot} O_{\cdot j}/N}.$$

Compara la actividad que se observa en la hoja con la que predecirían los volúmenes globales de sus regiones y de sus horarios. Como la hoja es un rectángulo, el denominador se simplifica a $\left(\sum_{i\in I_L} O_{i\cdot}\right)\left(\sum_{j\in J_L} O_{\cdot j}\right)/N$.

Ejemplo. Sea $N = 10\,000$ y una hoja con las regiones 1 y 2 y los horarios a y b. Los totales globales son $O_{1\cdot} = 500$, $O_{2\cdot} = 300$, $O_{\cdot a} = 1000$ y $O_{\cdot b} = 2000$. El esperado es $(500 + 300)(1000 + 2000)/10\,000 = 800 \cdot 3000/10\,000 = \mathbf{240}$. Si la hoja tiene $N_L = 360$ viajes, entonces $\ell_L = 360/240 = \mathbf{1.5}$. Ese grupo de regiones se activa en ese grupo de horarios un 50 % más de lo que corresponde a su volumen. Un valor menor que 1 indica lo contrario, que está más apagado de lo esperado.

Por qué la referencia es la matriz completa y no el padre. El modelo de independencia del bloque padre reproduce los totales de fila y de columna del padre. Tras un corte de filas, el esperado de cada hijo suma exactamente su masa, y el cociente respecto del padre vale 1 en todos los hijos, sin distinguir nada. En el bloque de 4000 viajes cortado en hijos de 3000 y 1000, respecto del padre ambos darían $3000/3000 = 1$ y $1000/1000 = 1$. Con la matriz completa como referencia, el cociente sí mide algo.

71.2. 2. Árbol anotado

Cada nodo interno muestra el tipo de corte, la ganancia corregida $\tilde{g}$ y el p-valor, de modo que se lee qué parte de la heterogeneidad fue espacial y cuál temporal. Cada hoja se lee como el resultado de la secuencia de cortes que llevó hasta ella, como las reglas de un árbol de decisión.

Ejemplo de lectura. Un bloque base se corta por filas ($\tilde{g} = 0.04$, $p = 0.005$) y uno de sus hijos se corta por columnas ($\tilde{g} = 0.01$, $p = 0.01$). La hoja resultante se lee como un grupo de regiones, dentro de ese bloque, en un grupo de horarios. La primera pregunta fue espacial y la segunda temporal.

71.3. 3. Matriz teselada

La matriz se reordena según la partición base y, dentro de cada bloque, según sus cortes. Se dibuja con los contornos de las hojas y un color proporcional a ℓ_L, como en la Figura 3.1. Da una vista global en la que los patrones locales aparecen como rectángulos de color distinto dentro de bloques que, en el tablero de ST-CC, se veían uniformes.

71.4. 4. Mapas de profundidad

Para cada región se dibuja la profundidad máxima que alcanza el refinamiento en sus filas, y análogamente para cada intervalo de tiempo. Si la región 5 aparece en hojas de profundidades 1, 3 y 2, su valor en el mapa es 3. Un mapa con profundidad uniforme indicaría que el tablero de ST-CC era suficiente. Las zonas con profundidades altas señalan las regiones y los horarios donde se concentra la interacción espacio-temporal local, es decir, dónde y cuándo la partición base es insuficiente.

71.5. 5. Frecuencia de soporte

BBAC$_I$ converge a mínimos locales y el refinamiento es voraz, así que el resultado puede cambiar con la inicialización. A cada hoja se le asigna su frecuencia de soporte, que es la proporción de ejecuciones, con distintas inicializaciones de la partición base, en que aparece una hoja con índice de Jaccard sobre celdas $\geq \kappa$ respecto de ella.

El índice de Jaccard entre dos conjuntos de celdas es $|A \cap B|/|A \cup B|$. Vale 1 si son idénticos y 0 si no comparten nada.

Ejemplo. Una hoja de 3×2 regiones y horarios tiene 6 celdas. En otra ejecución aparece una hoja de $2 \times 2 = 4$ celdas contenida en la primera. Entonces $|A \cap B| = 4$, $|A \cup B| = 6$ y $J = 4/6 \approx 0.67$. Con $\kappa = 0.7$ no se cuenta como la misma hoja, y con $\kappa = 0.5$ sí. Si la hoja aparece en 170 de 200 ejecuciones, su soporte es 0.85. Una hoja con soporte bajo no debe interpretarse como hallazgo.

Estado de la implementación. El cálculo de la frecuencia de soporte y del índice de Jaccard no aparece todavía en `Implementaciones`. Si el capítulo de resultados los va a reportar, hay que implementarlos. El valor $\kappa = 0.5$ y el criterio de soporte bajo (menos de la mitad de las ejecuciones) son propuestas que quedan por confirmar. Además, el comentario de `AST-CC/02_refinamiento.py` asigna la ecuación del nivel de actividad a la versión respecto del padre, cuando en la tesis esa ecuación es la global.

> Al abandonar el tablero se pierde la lectura sencilla de ST-CC, y los cinco productos la reconstruyen. Los descriptores dicen qué es cada hoja, el árbol anotado cómo se llegó a ella, la matriz teselada dónde está, los mapas de profundidad dónde y cuándo el tablero fue insuficiente, y la frecuencia de soporte cuánto se puede confiar en que no sea un accidente de la inicialización.

Parte XV
Capítulo 3, bloque 7: limitaciones y cierre

72. Por qué existe esta sección

Un método propuesto que solo muestra sus virtudes no es defendible. La sección 3.10 declara antes de los experimentos qué no puede hacer el diseño, cómo condiciona la lectura de los resultados y cómo se piensa medir el efecto de cada limitación. Por eso cada limitación viene con su forma de evaluarla. La sección termina con las extensiones que se consideraron y quedan fuera del alcance.

73. 3.10 Las ocho limitaciones

1. Restricción guillotina. El refinamiento solo mira hacia dentro de cada bloque, así que un patrón que cruce la frontera entre dos bloques base no se recupera como una hoja sino como hojas separadas. Por ejemplo, un patrón en las regiones 3 a 6 en las mismas horas, con las regiones 3 y 4 en el bloque base A y las 5 y 6 en el B, se recupera como dos hojas pequeñas y no como un rectángulo de cuatro regiones. Por eso se menciona como extensión un paso de fusión de hojas vecinas.

2. Dependencia de la partición base. El refinamiento parte de un óptimo local de BBAC_I, que tiene muchos mínimos locales. La búsqueda local, las múltiples inicializaciones y la frecuencia de soporte atenúan y miden el efecto. La base también importa, pues con C5 y con C2 se obtienen tableros muy distintos, y C5 deja menos interacción local por refinar, porque agrupa las regiones por la forma de su perfil y no por su volumen.

3. Resolución de entrada. Los cortes agrupan regiones e intervalos pero no los subdividen, así que el método no puede bajar de la resolución de la matriz, que son las zonas de taxi (de tamaños muy dispares) y los intervalos de dos horas.

4. Parámetros. El método no elimina K_R y K_T sino que cambia su papel. Fijan la resolución inicial, y la final la deciden α y δ, dos parámetros con interpretación directa. Esto solo se sostiene si el resultado es razonablemente estable frente a K_R y K_T, lo que debe comprobarse empíricamente.

5. Comparación con rejillas más finas. Cabe preguntar por qué no basta con subir K_R y K_T o elegirlos con Cross-Associations. La respuesta debe ser empírica, y consiste en comprobar que una rejilla global con el mismo número de parámetros, o con el mismo BIC, no recupera los patrones locales que encuentra AST-CC.

Ejemplo del conteo de parámetros. Sea $n = 12$ intervalos repartidos en $K_T = 4$ grupos de 3 columnas. Un corte de filas en un único bloque de 3 columnas añade $|J| - 1 = 2$ parámetros. Partir globalmente el mismo grupo de filas a lo largo de los 4 grupos de columnas añade $4 \cdot 2 = \mathbf{8}$. Los parámetros crecen con la estructura local encontrada y no con la resolución global.

6. Validez de las pruebas. La selección de nodos con los mismos datos puede inflar el error de tipo I. El *bootstrap* de días supone días independientes y usa E^B como estimación de las medias. Con pocos días, como en el feriado, es algo liberal en los bloques nocturnos (hasta 0.30 en el peor bloque de la calibración). Por eso es indispensable un experimento de calibración sobre datos nulos.

7. Costo frente a resolución. El reparto del nivel por masa da a los bloques con pocos viajes niveles menores que la resolución alcanzable con $B_{\text{máx}}$ réplicas.

Ejemplo. Con $N = 10^6$ y $\alpha = 0.05$, un bloque de 600 viajes recibe $\alpha_B = 0.05 \cdot 600/10^6 = 3 \cdot 10^{-5}$. Supera $N_{\text{mín}} = 500$, pero el p-valor mínimo con 20 000 réplicas es $1/20\,001 \approx 5 \cdot 10^{-5} > 3 \cdot 10^{-5}$, así que queda como hoja inalcanzable. Eso no es lo mismo que homogénea, porque el método no afirma que no haya nada sino que no puede probarlo al nivel asignado.

8. Significativo no es interesante. Una hoja puede tener heterogeneidad detectable y ser irrelevante en el dominio. Por eso se reporta siempre el tamaño de efecto junto al p-valor, y los patrones principales se contrastan con conocimiento del dominio, como el foco alrededor de Penn Station que identifican Liu y colaboradores.

74. Extensiones que quedan como trabajo futuro

Cada una se consideró durante el diseño y tiene un motivo para quedar fuera.

- **Control de FDR jerárquico (Yekutieli).** Es más permisivo que la FWER cuando se esperan muchos refinamientos. Se dejó fuera porque la FWER es la garantía más simple de interpretar en una primera versión del método.
- **Elegir y probar con días distintos.** Elegir la partición y los cortes con la mitad de los días y probarlos con la otra mitad elimina el doble uso de los datos a costa de potencia, en la línea del *count splitting*. Exige comprobar antes que la mitad de los días basta para estimar la partición.
- **Nulas paramétricas por celda.** Con una función de varianza como la ley de potencia de Taylor. No se adoptaron porque no reproducen las desviaciones correlacionadas entre las celdas de un bloque (sección 3.5).
- **Cortes de columnas en intervalos consecutivos.** Con doce intervalos hay $2^{11} - 1 = 2047$ biparticiones, pero solo 11 si deben respetar el orden del día. Serían más fáciles de interpretar y más baratos, a costa de no capturar horarios no contiguos, como las dos horas punta del día.

- **Fusión de hojas vecinas.** Recuperaría los patrones que cruzan bloques base, que es la limitación de la restricción guillotina.

75. Consideraciones finales del capítulo

El capítulo presentó AST-CC, una extensión de ST-CC que refina localmente la partición en tablero mediante un árbol de cortes guiados por pruebas de hipótesis. La pieza teórica central es la proposición de descomposición por hojas, según la cual la divergencia del árbol se reparte exactamente entre las hojas y la ganancia de cada corte es un estadístico de razón de verosimilitud. El corolario muestra que el método descompone el término de interacción local que ST-CC deja sin modelar, de modo que el criterio de refinamiento y la función objetivo de ST-CC son la misma cantidad vista a distintas escalas.

Sobre esa base, el método combina una prueba ómnibus calibrada con *bootstrap* de los días observados, pruebas dirigidas con ajuste *min-P*, un reparto jerárquico del nivel y un umbral de tamaño de efecto corregido por sesgo. Cada limitación tiene en el Capítulo 4 una forma de evaluarse, que es la calibración sobre datos nulos para la validez de las pruebas, la comparación con rejillas globales de igual número de parámetros para el valor del refinamiento local, y el análisis de sensibilidad a K_R, K_T, α y δ para la dependencia de la partición base y de los parámetros.

AST-CC conserva el tablero de ST-CC y le añade un refinamiento local cuyas decisiones son pruebas de hipótesis con error controlado. Sus límites son la restricción a cortes dentro de cada bloque, la dependencia de la partición base y la validez solo aproximada de las pruebas cuando el árbol se construye con los datos, y cada uno tiene un experimento previsto que lo mide.